

修士論文

視覚言語モデルにおけるタスク類似性に基づく
内部表現整合学習に関する検討

※題目は提出時に確定（プリアンプルの候補を参照）

中野 友晴

東京都立大学大学院 システムデザイン研究科
情報科学域

指導教員 杉村 大輔

提出日 ※未定

概要

視覚言語モデル（VLM）は画像と言語を併せて理解し、画像への質問応答など広く応用されている。従来の VLM は出力だけを目標に学習し、答えが同じでも内部表現は入力の変動で大きく動きうる。そこで本研究では、解き方が同じ質問の内部表現を近づける統合学習を検討する。これにより内部表現が解き方に沿って整い、答えの生成に使われると期待できる。実験の結果、正解率をほとんど変えずに解き方を内部表現から読み取りやすくなるが、モデルはそれを使うようにはならず、統合した表現への依存はむしろ下がることがわかった。

〔執筆メモ〕上の 250 字（講演申込と同文）を種に、読み手の知る地点から書き直して 800 字程度へ広げる（流れは VLM とは何か→従来の課題→提案と期待→結果）。頑健性の測定（context.md § 8.1）が済んだら、その結果もここに一文で入る。

目次

概要	i
第 1 章 序論	1
1.1 背景——出力の頑健性は、表現の頑健性を含意しない	1
1.2 本研究の問い	1
1.3 貢献	1
1.4 本論文の構成	1
第 2 章 関連研究	2
2.1 VLM の内部表現の不安定性	2
2.2 プロンプト——読み取れることと使われることの区別	2
2.3 対照学習	2
2.4 内部表現に手を入れる先行例	2
2.5 GQA と functional program	2
第 3 章 提案手法	3
3.1 タスク署名——解き方を、比べられる形にする	3
3.2 整合損失	3
3.3 どこに掛けるか——射影を挟まない中間層の一点	3
第 4 章 実験設定	4
4.1 モデルとデータ	4
4.2 三つの群	4
4.3 乱数種 3 つの、まとめ方	4
4.4 整合が働いたことの確認	4
第 5 章 結果	5
5.1 署名の読み取りやすさは、大きく上がる	5
5.2 正解率は、ほとんど動かない	5
5.3 読み取れるようになった構造は、使われていない	5
5.4 表現の頑健性——整合した表現は、入力の揺らぎに安定するか	5
第 6 章 結論	6
6.1 結論と貢献	6

6.2	限界	6
6.3	今後の課題	6
謝辞		7
参考文献		8
付録 A	補助的な検証	9
A.1	「読み取りやすさ」の測定と、二つの対照	9
A.2	演算子の組成も、読み取れるようになる	9
A.3	正解率が上がらない理由——頻度層別と、正誤で分けたプローブ	9
A.4	「使われていない」を、どう測ったか——三段の測定	9
A.5	整合する層を変えた試走——乱数種 1 つ	9

第 1 章

序論

1.1 背景——出力の頑健性は、表現の頑健性を含意しない

〔執筆メモ〕 context.md § 1.1. VLM の頑健性は出力で測られてきたこと, Wani ら [1] が「答えが変わらないまま内部表現が大きく変化する」ことを示したこと（幾何的な加工と文字の重ね書きの違いまで), 著者ら自身は対処法を示していないこと.

1.2 本研究の問い

〔執筆メモ〕 context.md § 1.2. Wani らは同じ入力揺らぎを見ており, 別々の質問どうしの近さは問われていない——そこから入る. 中心の問いは一つ: タスク構造 (署名) を内部表現に明示的に整合させたとき, 内部表現と答えの生成に何が起きるか. 正解率の向上は目的ではないことをここで明言する.

1.3 貢献

〔執筆メモ〕 context.md § 2. 貢献は「読み取れること」と「使われること」を分けて示したこと. Elazar ら [2] の「除く」方向に対し, 本研究は損失で「足す」方向から構成的に示す. VLsI [3] は傍証にとどめ, 中核の支柱には据えない (教師あり蒸留と自己整合の違い).

1.4 本論文の構成

〔執筆メモ〕 各章の一文紹介. 最後に書く.

第 2 章

関連研究

2.1 VLM の内部表現の不安定性

〔執筆メモ〕 references/hidden-instability.md. Wani ら [1] の設定（言語側最終層, Qwen3-VL・LLaVA-OneVision, SEEDBench・MMMU・POPE）と指標（無関係画像対の距離分布を基準にした比）. 本研究が借りるのは指標の形だけである.

2.2 プロブ——読み取れることと使われることの区別

〔執筆メモ〕 references/probing-classifiers.md・amnesic-probing.md・task-format.md. Belinkov [4] の総覧, Elazar ら [2] の amnesic probing（除いて測る・Rand 対照）, Sahoo ら [5] の「プロブは task format を検出しうる」という警告. 本研究の測定設計（言い回しプロブ・書き出し分離・残差化）がどの批判に応えるものかをここで対応づける.

2.3 対照学習

〔執筆メモ〕 references/supcon.md. SupCon [6] の損失と射影 head. 本研究は射影を挟まず（反証可能性のため）生の表現に掛ける点が異なる——詳細は 3.3 節.

2.4 内部表現に手を入れる先行例

〔執筆メモ〕 references/vlsi.md. VLsI [3]（層ごとの特徴を自然言語化して蒸留, 正解率向上）. 外部教師の有無・表現を直接近づけるか否かの違い.

2.5 GQA と functional program

〔執筆メモ〕 references/gqa.md. GQA [7] の構成と functional program. program が付いていることが採用理由であること.

第 3 章

提案手法

3.1 タスク署名——解き方を，比べられる形にする

〔執筆メモ〕 context.md § 3.1. functional program の例 (“Who is wearing the dress?” の 3 段の表)，署名の定義，引数を捨てる理由，署名と質問文の交絡（自動生成ゆえの相関，演算子名が質問文に現れる 10 種）.

3.2 整合損失

〔執筆メモ〕 context.md § 3.2. SupCon 式 ($\mathcal{L}_{\text{align}}$) と各項の読み， $\mathcal{I}$ から外れる質問が本研究のバッチ構成では生じないこと，温度 τ （学習可能，初期値 0.07），全体の目的関数 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ ($\lambda = 0.1$).

3.3 どこに掛けるか——射影を挟まない中間層の一点

〔執筆メモ〕 context.md § 3.3. 第 16 層・質問を読み終えた位置 ($H = 960$) の選定理由（causal attention のもとで画像と質問文を読み終えている唯一の位置），射影 head を挟まない理由（反証可能性），それでも構造が使われない余地が残ること（多対一の写像）——この余地を測るのが 5.3 節である.

第 4 章

実験設定

4.1 モデルとデータ

〔執筆メモ〕 context.md § 4.1. SmolVLM-500M-Instruct [8] (32 層, $H = 960$), GQA `train_balanced` 1 エポック (884 問除外, 942,116 問), バッチ構成 (16 署名 $\times$ 2 件), 学習率・勾配打ち切り, 9 回の学習 (3 群 $\times$ 3 乱数種, 1 回約 2 時間 53 分), `testdev_balanced` 12,578 問で報告する理由と 3 分割の排他性.

4.2 三つの群

〔執筆メモ〕 context.md § 4.2. `baseline` / `proposal` / `ablation` の定義. `ablation` は「ラベルの意味だけを除く」群であり表現を壊す群ではないこと, この対照が答えるのは「ラベルに意味が要るか」までで「署名である必要があるか」ではないこと (→ 6.3 節).

4.3 乱数種 3 つの, まとめ方

〔執筆メモ〕 context.md § 4.3. 対応のある t 検定と 95% 信頼区間 ($n = 3$, $t_{2,0.975} = 4.303$), 「区間が 0 を含む=差が無い, ではない」という読み方, `baseline` 3 本で測る乱数種由来のばらつき (幅 1.14pt).

4.4 整合が働いたことの確認

〔執筆メモ〕 context.md § 4.4. 分離度 δ (Cohen's d) の定義と 3 群の値 (0.816 / 2.378 / 0.451), `proposal` は「同署名を近づけた」のではなく異署名がそれ以上に離れた結果であること, `ablation` の表現が一方方向に潰れたことと $\log 31$ への一致 (ラベルに情報が無いことの裏づけ).

第 5 章

結果

5.1 署名の読み取りやすさは、大きく上がる

〔執筆メモ〕 context.md § 5.1（当てはめの詳細は付録 A.1）. 読み取り精度の表（82.9% → 95.9%, +13.0pt ; ablation 81.0% ; 言い回しプロープ 69.7% ; 床 28.8% ; 書き出し分離で +14.5pt）. 「上がったこと自体は発見ではない」——確定させるのは増分の帰属であるという書き方を保つ. 整合前の baseline の読み（幾何は近くないが線形には読める）もここ. 組成への波及は付録 A.2 へ送る.

5.2 正解率は、ほとんど動かない

〔執筆メモ〕 context.md § 5.2. 乱数種ごとの正解率の表, proposal - baseline の区間 $[-1.81, +1.70]$ の計算過程, 「差が無い」ではなく上限を言う読み方. 上がらない理由の層別は付録 A.3 へ送る.

5.3 読み取れるようになった構造は、使われていない

〔執筆メモ〕 context.md § 5.3（測定方法は付録 A.4）. 弾性の表（3 幅で - 28.0 / - 21.6 / - 18.0%, ablation は下がらない）, 特権の消失（+2.82pt → 差なし）, 一次近似であることの留保（「まったく使っていない」ではなく「頼る度合いが下がった」）.

5.4 表現の頑健性——整合した表現は、入力の揺らぎに安定するか

〔執筆メモ〕【未測定——この測定が済むまで本論文は書き始めない】 context.md § 8.1. 出発点（1.1 節）に応える測定 : 3 群に正解を変えない画像加工を施し, 第 16 層の表現の変化量を無関係画像対の距離分布を基準にした比で比べる. 結果が 3 通りのどれか（安定性を高める / 形式だけ / 脆くなる）で 6 章の枠組みが変わる. 9 回の学習の重みは E:\runs（USB バックアップあり）にある.

第 6 章

結論

6.1 結論と貢献

〔執筆メモ〕 context.md § 6. 三つの主結果を一文で束ねる．貢献（足す側から構成的に示した），「この研究から言えないこと」の列挙をここでも省かない——頑健性（5.4 節）の結果が出たら，束ねる一文はそれを含む形に書き直す．

6.2 限界

〔執筆メモ〕 context.md § 7. 設計の一点性（ $\lambda = 0.1$ ・第 16 層・単一モデル・単一データセット・1 エポック），署名が解き方の正しい形式化かは未検証（GQA 公式 consistency との食い違い 52.1% の読み方を含む），「使われていない」は第 16 層・一次近似の範囲であること．

6.3 今後の課題

〔執筆メモ〕 context.md § 8. 執筆時点で残っているものだけを書く（済んだ測定は 5 章へ移す）：稀な署名の表現側の層別（§ 8.2），答えの型ラベルでの整合——主語の確定（§ 8.3）， λ と層を振る・別モデルと別データセット（§ 8.4，署名に代わる形式化が要ること）．

謝辞

〔執筆メモ〕 指導教員・研究室・（あれば）計算資源等への謝辞。最後に書く。

参考文献

- [1] F. A. Wani et al.: “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] Y. Elazar et al.: “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” TACL, vol. 9, pp. 160–175, 2021.
- [3] B.-K. Lee et al.: “VLsI: Verbalized Layers-to-Interactions from Large to Small Vision Language Models,” CVPR, 2025.
- [4] Y. Belinkov: “Probing Classifiers: Promises, Shortcomings, and Advances,” Computational Linguistics, vol. 48, no. 1, pp. 207–219, 2022.
- [5] S. Sahoo et al.: “Linear Probes Detect Task Format, Not Reasoning Mode in Language Model Hidden States,” 6th Workshop on Trustworthy NLP, ACL 2026.
- [6] P. Khosla et al.: “Supervised Contrastive Learning,” NeurIPS, 2020.
- [7] D. A. Hudson and C. D. Manning: “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” CVPR, 2019.
- [8] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [9] T. McGrath et al.: “The Hydra Effect: Emergent Self-repair in Language Model Computations,” arXiv:2307.15771, 2023.
- [10] W. Gurnee et al.: “Verbalizable Representations Form a Global Workspace in Language Models,” Transformer Circuits Thread, 2026.

付録 A

補助的な検証

A.1 「読み取りやすさ」の測定と、二つの対照

〔執筆メモ〕 context.md § A.1. プロープの定義・当てはめと打ち切り（10 問以上の署名に限る, 1/2 分割, early stopping）・床の定義, 言い回しプロープと書き出し分離の作り方, ablation の 81.0% の読み方, 残差化（Sahoo ら [5] への応答, 形式 3 変量で 0.35pt しか動かない）——残差化はこの付録限定とする.

A.2 演算子の組成も, 読み取れるようになる

〔執筆メモ〕 context.md § A.2. 「学習が教えたことを読み返しているだけ」への反論の設計（署名単位の分割・演算子集合ラベル）, AUC と完全一致率の表（36.3% → 44.5%）, 言い回しプロープとの比較の読み方の注意.

A.3 正解率が上がらない理由——頻度層別と, 正誤で分けたプロープ

〔執筆メモ〕 context.md § A.3. 署名の学習出現回数による 5 層の層別表（利得の現れる層は無い, 1–10 層の – 2.50pt は区間が 0 を跨ぐ）, 正誤で分けたプロープ（誤答側でも 96.4%——誤りは署名より後の段階）, proposal に掛かる留保. 稀な署名の表現側の測定（§ 8.2）が済んだらここに足す.

A.4 「使われていない」を, どう測ったか——三段の測定

〔執筆メモ〕 context.md § A.4. 中立／不一致の二択, 自己修復 [9] ゆえに壊す方法を採用しないこと, 三段の設計 (U_m ・J-lens [10] による引き戻し $J(U_m)$ ・弾性 $e_p(u)$) と判定量 Δ_m / Δ'_m , 結果の表と各段の読み（第 1 段は決着に使わない, など）, 64 問で足りることの確認.

A.5 整合する層を変えた試走——乱数種 1 つ

〔執筆メモ〕 context.md § A.5. 第 8 層・第 24 層（乱数種 42）の表, 読み取り精度は層を変えても同じ高さに着くこと, 区間を作れない旨. 乱数種を揃える追試（§ 8.4）が済んだら本文へ昇格を検討する.