

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

杉村 大輔[†]

Tomoharu Nakano[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) など多くのタスクに応用されている。一方で、入力の変動で答えは同じでも内部表現が大きく変わることが知られており、解き方 (タスク構造) が同じ別々の質問の内部表現が近いかは未解明である。本研究では、タスク構造を署名として形式化し、署名が一致する質問間で内部表現を近づけるタスク類似性に基づく内部表現整合学習を検討する。これにより内部表現がタスク構造に沿って整い、答えの生成に使われるようになると期待できる。この仮説を検証した結果、正解率をほとんど変えずに内部表現から解き方を大きく読み取りやすくなった一方で、モデルはそれを答えの生成に使うようにはならず、依存はむしろ下がること示唆された。

1 はじめに

Wani ら [1] は、視覚言語モデル (VLM) で、正解を変えない画像の加工に対し、答えが変わらないまま内部表現が大きく変化しうること示した。ただし、扱われたのは同じ入力の変動であり、別々の質問の内部表現が近いかは問われていない。本研究では、解き方が同じ質問どうしの内部表現を明示的に近づける補助損失 (以下、整合) を通常の学習に加え、次の三点を調べる。(1) 解き方は内部表現から読み取りやすくなるか、(2) 正解率に代償はあるか、(3) 読める構造は答えの生成に使われるか、である。

性質が線形分類器 (プローブ) で内部表現から読み取れることと、モデルがそれを答えの計算に使うことは別である [2]。Elazar ら [3] は、言語モデルの内部表現から句境界などの性質を線形に除去して語予測への影響を測り、高い精度で読み取れる性質でも除去して性能がほとんど変わらない例を示した。本研究はこれと逆向きに、性質を損失で内部表現に作り込む。作り込めば使われるという暗黙の期待に反して、モデルはその構造を使うようにはならず、依存はむしろ下がる。使われる度合いを除去後の性能ではなく答えの感度で測るのは、除いた働きを別の層が肩代わりする自己修復 [4] を避けるためである。

2 提案手法

2.1 タスク署名

VQA データセット GQA [5] の各質問には、答えに至る手順を記述した functional program が付与されている。例えば “Who is wearing the dress?” の program は `select > relate > query` である。この演算子列をタスク署名 (以下、署名) と呼び、署名が一致する質問対を正例対とする。引数は捨てる。

2.2 整合損失と適用位置

バッチ内の B 件の内部表現 $h_i \in \mathbb{R}^H$ と署名ラベル y_i ($i = 1, \dots, B$) に対し、 $z_i = h_i / \|h_i\|_2$, $s_{ij} = z_i^\top z_j$, $P(i) = \{j \neq i \mid y_j = y_i\}$ とおく。整合損失には、署名をラベルとする supervised contrastive loss [6]

$$\mathcal{L}_{\text{align}} = \frac{1}{|I|} \sum_{i \in I} \left[\log \sum_{j \neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|} \sum_{p \in P(i)} \frac{s_{ip}}{\tau} \right] \quad (1)$$

を用いる ($I = \{i \mid P(i) \neq \emptyset\}$)。温度 τ は学習可能 (初期値 0.07) とする。目的関数は $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ であり、 $\mathcal{L}_{\text{LM}}$ は答えのトークンのみに掛かる交差エントロピー、 $\lambda = 0.1$ は整合の強さである。

整合損失は、言語モデル部 (32 層) の第 16 層において、質問を読み終えて答えを書き出す直前の位置のベクトル ($H = 960$) に適用する。画像と質問文を読み終えた唯一の位置であり、答えの先頭トークンもここから選ばれる。原論文 [6] と異なり射影 head は挟まない。学習可能な射影は、内部表現を変えずに損失を下げる経路になるためである。

3 実験設定

モデルは SmolVLM-500M-Instruct [7] を用い、GQA の `train_balanced` (正例対を組めない 884 問を除く 942,116 問) で 1 エポック学習する。バッチは、正例対を組める署名から質問数によらず一様に 16 署名を選び、各 2 問ずつの 32 問とする。1 エポックは 29,441 バッチであり、学習率は 10^{-5} である。次の 3 群を 3 乱数種で学習する。整合損失を用いない baseline ($\lambda = 0$)、署名をラベル y_i とする proposal、 λ と損失の形は同じままバッチ内でラベルを無作為に並べ替える ablation である。並べ替えはラベルの分布と正例対の数を保ち意味だけを取り除くので、

表 1: 署名の読み取り精度と正解率 (3 乱数種の平均)

	読み取り精度		正解率
	通常	書き出し分離	
baseline	82.9%	80.9%	53.54 ± 0.57
proposal	95.9%	95.4%	53.49 ± 0.31
ablation	81.0%	78.6%	53.57 ± 0.25
言い回し	69.7%	66.1%	—

proposal のみが異なればその差はラベルの意味に帰属できる. 評価は `testdev_balanced` の 12,578 間で行い, 3 乱数種の平均を報告する. 群間差の判定には, 正解率では乱数種を対にした t 検定の 95%信頼区間を, 他では乱数種ごとの差の符号を用いる.

4 結果

4.1 署名の読み取り精度

整合損失を適用したベクトルから署名を予測する線形プロープの正解率を読み取り精度と呼ぶ. 10 問以上ある 145 署名・10,990 問を, 当てはめ用と評価用に半分ずつ分けて測る. GQA の質問文は program から自動生成されるため言い回しと署名は相関し, 読み取り精度は語の暗記でも説明されうる. そこで二つの対照を置く. 言い回しプロープは, 内部表現の代わりに質問文の語 (と隣接 2 語の組) の有無を入力とする同じ線形分類器である. 書き出し分離は, 先頭 4 語が同じ質問を同じ側に寄せる分割であり, 評価用の書き出しは必ず未見となる.

表 1 のとおり, 整合により読み取り精度は +13.0pt 上がり, ablation では上がらないので, 増分はラベルの意味に帰属する. 暗記に頼る言い回しプロープは書き出し分離で精度を落とすが, proposal はほとんど落ちず, 増分は +14.5pt とむしろ広がるので, 増分は言い回しでは説明できない.

4.2 正解率

貪欲デコードで答えを生成し, GQA 公式の評価器で採点する (表 1 右列). proposal と baseline の差は平均 -0.06 , 95%信頼区間 $[-1.81, +1.70]$ であり, 0 を含む. 低下は大きくとも 1.81pt であり, 正解率の面での代償はほぼ無い.

4.3 第 16 層への依存

答えの先頭トークンに対応する出力層の行を中心化し, その上位 m 本の主成分を U_m とする. U_m は答えどうしのスコア差を最も動かす方向である. U_m の各列 u について, 第 16 層のベクトル h から読み出し r (最終層の同じ

表 2: 答えを決める方向への相対感度 (3 乱数種の平均)

	$m = 8$	$m = 32$	$m = 128$
baseline	0.4023	0.2997	0.2415
proposal	0.2883	0.2341	0.1973
ablation	0.3833	0.2972	0.2419

位置のベクトル) へのヤコビ行列 J を用いて [8], 相対感度 $e = \|J^\top u\| \|h\| / \|r\|$ を求める. これは第 16 層を相対的に 1%動かしたとき読み出しが u 方向へ何%動くかを表し, m 本の方向と評価データ 64 間で平均する (表 2).

proposal の相対感度は, 乱数種ごとに baseline との比をとって平均すると 18–28%下がり, 3 乱数種すべてで符号が揃う. ablation では下がらない. 低下はラベルの意味に帰属し, 答えは整合を適用した位置に以前より頼らなくなった. したがって 4.1 節の +13.0pt は, 署名が答えの生成に使われるようになったことを意味しない. ただし相対感度は一次近似であり, 言えるのは依存が下がったことまでである.

5 むすび

整合により, 正解率をほとんど変えずに署名は読み取りやすくなるが, モデルはそれを答えの生成に使うようにはならず, 第 16 層への依存はむしろ下がる. 本結果は $\lambda = 0.1$, 第 16 層, 単一のモデルとデータセットで得た一点のものであり, 署名が解き方の適切な形式化か, 効果があるラベル一般に生じるかは未検証である. 今後は答えの型のラベルで整合してこの区別をつけ, 画像加工前後の内部表現の変化を測り, λ と層を変える.

参考文献

- [1] F. A. Wani et al.: “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] Y. Belinkov: “Probing Classifiers: Promises, Shortcomings, and Advances,” Computational Linguistics, vol. 48, no. 1, 2022.
- [3] Y. Elazar et al.: “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” TACL, vol. 9, 2021.
- [4] T. McGrath et al.: “The Hydra Effect: Emergent Self-repair in Language Model Computations,” arXiv:2307.15771, 2023.
- [5] D. A. Hudson and C. D. Manning: “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” CVPR, 2019.
- [6] P. Khosla et al.: “Supervised Contrastive Learning,” NeurIPS, 2020.
- [7] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [8] W. Gurnee et al.: “Verbalizable Representations Form a Global Workspace in Language Models,” Transformer Circuits Thread, 2026.