

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

杉村 大輔[†]

Tomoharu Nakano[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) をはじめ多岐にわたるタスクに応用されている。従来の VLM は出力の正答率を最適化するように学習されるため、同一の解法 (タスク構造) を要する問いであっても、入力わずかな揺らぎによって内部表現が大きく変動するという課題がある。そこで本研究では、類似したタスク構造を持つ質問間で内部表現を近づける、タスク類似性に基づく内部表現整合学習を検討する。これにより内部表現がタスク構造に沿って整い、出力の生成に使われると期待できる。実験の結果、タスク正答率を維持したまま内部表現から解法構造を読み取りやすく改善する一方で、モデルはその整合された内部表現を出力生成に使うようにはならず、むしろ依存を弱めることが示唆された。

1 はじめに

Wani ら [1] は視覚言語モデル (VLM) で、正解を変えない画像の加工に対し、答えが変わらないまま内部表現が大きく動くことを示した——答えが変わらないこと (出力の頑健性) は表現の頑健性を含意しない。ただしそれは同じ入力の揺らぎで、別々の質問どうしの近さは問われていない。本研究はそこから入り、解き方が同じ質問どうしの内部表現を明示的に近づける補助損失 (以下、整合) を通常の学習に足して、三つを問う: (1) 解き方は表現から読み取りやすくなるか、(2) 正解率に代償はあるか、(3) 読める構造は答えの生成に使われるか (4.1–4.3 節)。正解率の向上は目的ではなく、表現の頑健性そのものも本稿では測らない。

性質が線形分類器 (プローブ) で読み取れることと、モデルがそれを答えの計算に使うことは別である [2]。Elazar ら [3] は既にある性質を除いて示したが、本研究は性質を損失で足して構成的に示す: ほぼ無代償に読み取れる形へ作り込んでも、モデルはそれを使うようにはならず、依存はむしろ下がる。

2 提案手法

2.1 タスク署名

VQA データセット GQA[4] の各質問には、答えに至る道筋を書いた functional program が付く。例えば “Who is wearing the dress?” の program は `select > relate > query` (dress を選び、着ている人をたどり、答える) であり、この演算子列を**タスク署名** (以下、署名) と呼び、署名が一致する質問対を**正例対**とする (引数は捨てる。残すと正例対がほぼ同じ質問になる)。質問文は program か

ら自動生成されるため言い回しと署名は関連する——この交絡は 4.1 節で切り分ける。

2.2 整合損失と掛ける位置

バッチ B 件の内部表現 $h_i \in \mathbb{R}^H$ と署名ラベル y_i ($i = 1, \dots, B$) について、 $z_i = h_i / \|h_i\|_2$ 、コサイン類似度 $s_{ij} = z_i^\top z_j$ 、正例の集合 $P(i) = \{j \neq i \mid y_j = y_i\}$ とし、整合損失を署名をラベルとする supervised contrastive loss [5]

$$\mathcal{L}_{\text{align}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \left[\log \sum_{j \neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|} \sum_{p \in P(i)} \frac{s_{ip}}{\tau} \right] \quad (1)$$

とする ($\mathcal{I} = \{i \mid P(i) \neq \emptyset\}$)。温度 τ は学習可能 (初期値 0.07) で、目的関数は整合の強さ $\lambda = 0.1$ で $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ ($\mathcal{L}_{\text{LM}}$ は答えのトークンにのみ掛かる交差エントロピー) とする。

整合損失は、言語側 32 層の中間の第 16 層の、質問を読み終えて答えを書き出す直前の位置のベクトル ($H = 960$) に掛ける。causal attention のもとで画像と質問文を読み終えた唯一の位置で、答えの先頭トークンもここから選ばれる。原論文 [5] と異なり射影 head は挟まない——学習可能な射影は、表現を変えずに損失を下げる道を残す。

3 実験設定

モデルは SmolVLM-500M-Instruct[6]、学習は GQA の `train_balanced` (正例対を組めない 884 問を除く 942,116 問) で 1 エポック、バッチは 16 署名から 2 件ずつの 32 件、学習率は 10^{-5} 。3 群を乱数種 42・43・44 で学習した (計 9 回): 整合損失を掛けない **baseline** ($\lambda = 0$)、ラベル y_i を署名とする **proposal**、 λ も損失の形も同じままバッチ内でラベルを無作為に並べ替える **ablation** である。並べ替

表 1: 署名の読み取り精度と正解率 (3 乱数種の平均)

	読み取り精度	正解率
baseline	82.9%	53.54 ± 0.57
proposal	95.9%	53.49 ± 0.31
ablation	81.0%	53.57 ± 0.25
床 (最多署名の割合)	28.8%	—

えはラベルの分布と正例対の数を保ち、正例対の意味だけを除く——proposal が他の 2 群と違って初めて、差は対照学習の形式ではなくラベルの意味に帰属する。ablation の表現はコサイン類似度 0.99 超まで一方向に集まるが、署名の読み取り精度は baseline 水準を保ち (4.1 節)、対照として働く。報告は testdev_balanced 12,578 問 (質問も画像も学習と排他)、数値は 3 乱数種の平均である。正解率の群間差は乱数種を対にした t 検定の 95%信頼区間で判定し ($n = 3$)、読み取り精度と弾性は乱数種ごとの差の向きが揃うかで見える。

4 結果

4.1 読み取り精度はラベルの意味で上がる

整合損失が触るベクトルそのものから署名を当てる線形プロープの正解率 (読み取り精度) を測る (10 問以上ある 145 署名・10,990 問を半分に分け、当てはめと評価に用いる)。上がる向きは損失の定義から予想されるので、確かめるのは増分の帰属である。整合で 82.9% から 95.9% へ +13.0pt 上がり (表 1 左列)、ablation では上がらない (81.0%) ——増分はラベルの意味に帰属する。語の有無だけを入力にした同じ分類器 (言い回しプロープ) は 69.7% にとどまり (隣接 2 語組を足しても上がらない)、質問の書き出し (先頭 4 語) を評価側で未見にする分割でも増分は +14.5pt ——言い回しでは説明できない。

4.2 正解率はほとんど動かない

貪欲デコードで答えを作らせ、GQA 公式の評価器で採点する (表 1 右列)。proposal と baseline の差は平均 -0.06 、95%信頼区間 $[-1.81, +1.70]$ で 0 を跨ぐ (他の群間も同様)。低下は最大でも 1.81pt ——署名の可読化は正解率の面ではほぼ無代償である。

4.3 使うようにはならず、依存は下がる

答えを決める出力層の方向 (答えの先頭トークン行の主成分 m 本) を第 16 層へ線形化して引き戻し [7]、第 16 層を相対 1% 動かしたとき読み出しがその方向へ何% 動くか (弾性) を測った (表 2)。

表 2: 答えを決める方向への弾性 (3 乱数種の平均)

	$m = 8$	$m = 32$	$m = 128$
baseline	0.4023	0.2997	0.2415
proposal	0.2883	0.2341	0.1973
ablation	0.3833	0.2972	0.2419

proposal の弾性は 3 幅とも 18–28% 下がって 3 乱数種で向きが揃い、ablation では下がらない——低下はラベルの意味に帰属し、**答えは、整合が触った位置に以前より頼らなくなる**。整合前は答えを決める m 方向の中で署名が無作為な m 方向の中でより読めた ($m = 8$ で +2.82pt) が、整合後はこの差も消える (-0.26 pt) ——読める構造は答えを決める方向に集中もしていない。したがって +13.0pt は表現の形式の組み替えであり、署名が使われるようになったことを意味しない (弾性は一次近似の感度で、言えるのは「頼る度合いが下がった」までである)。

5 むすび

署名で整合させると、署名は線形にずっと読み取りやすくなり、正解率はほとんど動かないが、モデルはその構造を使うようにはならず、第 16 層への依存はむしろ下がる——読み取り精度の向上を「タスク構造を使うようになった」と読んではならない。本結果は $\lambda = 0.1$ ・第 16 層・単一モデル・単一データセットの一点のものである。署名が解き方の正しい形式化か、効果が署名に固有意義のあるラベル一般のものか (ablation が除くのはラベルの意味だけである) は未検証である。今後は、署名を粗く分ける答えの型ラベルで整合してこの区別をつけ、出発点の表現の頑健性 (画像加工前後の表現変化) を測り、 λ と層を振る。

参考文献

- [1] F. A. Wani et al.: “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] Y. Belinkov: “Probing Classifiers: Promises, Shortcomings, and Advances,” Computational Linguistics, vol. 48, no. 1, 2022.
- [3] Y. Elazar et al.: “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” TACL, vol. 9, 2021.
- [4] D. A. Hudson and C. D. Manning: “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” CVPR, 2019.
- [5] P. Khosla et al.: “Supervised Contrastive Learning,” NeurIPS, 2020.
- [6] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [7] W. Gurnee et al.: “Verbalizable Representations Form a Global Workspace in Language Models,” Transformer Circuits Thread, 2026.