タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴 † 杉村 大輔 †

Tomoharu Nakano† Daisuke Sugimura†

† 東京都立大学

†Tokyo Metropolitan University

Abstract: 視覚言語モデル（VLM）は画像とテキストを包括的に理解するモデルであり，視覚的質問応答などに応用されている．VLM の内部表現は，答えが同じ質問でも，画像の違いに伴い大きく変わることがある．これは，「見つける」,「たどる」,「答える」といった人間が回答を行う手続きの特徴について，VLM が一貫した内部表現を獲得していない可能性を示唆する．そこで本研究では，回答の手続きを各段階の操作の名前の並びとして明示的に扱い，手続きが一致する質問同士の内部表現を近づける，タスク類似性に基づく内部表現整合学習を検討する．実験の結果，類似タスクにおける内部表現の一貫性は回答の正解率には大きくは寄与しないことが確認できた．

1 はじめに

視覚言語モデル（Vision-Language Model; VLM）は画像とテキストを包括的に理解するモデルであり，画像に関する質問に答える視覚的質問応答（Visual Question Answering; VQA）などに応用されている．

多くの VLM は正しい回答を出力するよう学習され，VLM の内部表現がどう形成されるべきかは学習の目的に含まれない．Wani ら [1] は，質問の正解が変わらない範囲で画像に文字を重ねるなどの加工を施すと，加工の前後で VLM の回答が同じでも，その内部表現が大きく変化していることを示した．このように回答が同じでも内部表現が大きく変わることから，質問に回答する手順，例えば「見つける」,「たどる」,「答える」といった，人間が画像を見て回答に至るまでの手続きの特徴を，VLM の内部表現は獲得できていない可能性が考えられる．一方，質問中の物体が異なっても，回答の手続きが同じ質問は多い．よって，手続きが同じ質問同士，すなわち類似するタスク間で，内部表現を近づけることが重要と考えられる．

そこで本研究では，手続きが同じ質問同士の内部表現を近づけ，手続きが異なる質問同士を遠ざける，タスク類似性に基づく内部表現整合学習を提案する．これにより，回答に至るまでの手続きの特徴が，質問中の物体によらず一貫した形で内部表現を制約することができる．本稿では，このような VLM の内部表現を整合させることが，VQA にどのように寄与するのか検証する．

2 提案手法

2.1 提案手法の概要

図 1 に提案手法の概要を示す．VLM には，SmolVLM-500M-Instruct[2] を用いる．VLM は，画像を特徴に変える視覚エンコーダと，画像の特徴と質問文のトークン列から回答を生成する 32 層の言語モデル部から成る．自己回帰型言語モデルにおけるマスク付き自己注意機構に基づき，各トークンは自身以前のトークンのみ参照する．このことから，本研究では，画像と質問文のすべてを参照する入力末尾のトークンに着目する．末尾のトークンが第 16 層で持つ 960 次元の潜在特徴 $\boldsymbol{h}$ を，VLM の内部表現として利用する．学習には，言語モデル損失 $\mathcal{L}_{\mathrm{LM}}$ と，本研究で導入する整合損失 $\mathcal{L}_{\mathrm{align}}$ を用いる．これにより，VLM は正しい回答を生成しつつ，類似するタスクのデータ間での内部表現を近づけるよう学習される．

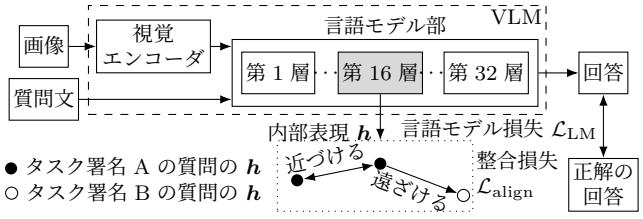


図 1: 提案手法の概要

2.2 タスク署名

提案手法では，回答に至る手順が同じかどうかを明示的に扱う．手順の判定には，VQA のデータセット GQA[3] の各質問に付与された，回答の手順を記述した functional program を用いる．functional program の各段は，select や relate のような操作の名前と，dress や wearing のような操作の対象から成る．本稿では，各段の操作の名前だけを実行順に記号>でつないだ列をタスク署名と呼び，タスク署名が完全に一致する質問同士は手順が同じとみなす．例えば “Who is wearing the dress?” と “What is the boy wearing?” は，それぞれ dress と boy を見つけ，wearing の関係の相手をたどり，名前を答える三段で回答できる．両者のタスク署名はともに `select > relate > query` で

ある．操作の対象を除くのは，対象まで含めるとタスク署名が一致する質問が対象も同じ質問に限られ，手順が同じ質問同士を近づけられないためである．

2.3 学習方法

整合損失 $\mathcal{L}_{\text{align}}$ には，画像分類で同じクラスの例の特徴を近づけ，異なるクラスの例の特徴を遠ざける supervised contrastive loss[4] を採用する．提案手法では，$\boldsymbol{h}$ に対応するタスク署名をクラスとして扱う．バッチ内の B 個の質問について，i 番目と j 番目の質問の内部表現 $\boldsymbol{h}_i$ と $\boldsymbol{h}_j$ のコサイン類似度を s_{ij}，質問 i とタスク署名が一致する他の質問の集合を $P(i)$ とし，次式で計算する．

$$\mathcal{L}_{\text{align}} = \frac{1}{B}\sum_{i=1}^{B}\Big[\log\sum_{j\neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|}\sum_{p\in P(i)}\frac{s_{ip}}{\tau}\Big] \quad (1)$$

ここで，第一項は他の全質問との類似度を，第二項はタスク署名が一致する質問との類似度を表す．また，τ は学習可能な温度パラメータであり，初期値を 0.07 とする．

言語モデル損失 $\mathcal{L}_{\text{LM}}$ は，正しい回答を生成するように制約する交差エントロピーである．VLM のパラメータは，λ を重みとする和 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda\mathcal{L}_{\text{align}}$ を最小化するよう更新する．

3 実験

3.1 実験概要

比較手法は，$\lambda = 0$ とし，言語モデル損失のみを用いて学習した baseline と，$\lambda = 0.1$ とした提案手法の proposal の二つである．学習には，GQA が学習用に配布している `train_balanced` から 942,116 問を用いた．各バッチは，無作為に選んだ 16 種のタスク署名から各 2 問，計 32 問とした．VLM のパラメータは，バッチごとに，学習データの問数を 32 で割った 29,441 回更新した．

学習に用いない `testdev_balanced` の 12,578 問に対し，三つの指標を用いて評価した．第一の指標は，GQA 公式の評価プログラムで採点した正解率である．

第二の指標は読み取り精度であり，$\boldsymbol{h}$ からタスク署名を予測する線形分類器の正解率である．線形分類器の学習と評価には，評価データのうち 10 問以上あるタスク署名の 10,990 問を無作為に二分して用いた．

第三の指標は相対感度である．線形分類器で読み取れる情報が回答の生成に用いられるとは限らない [5] ため，回答の生成が $\boldsymbol{h}$ に依存する度合いを測る．回答の最初のトークンである先頭トークンは，VLM の出力層が選ぶ．出力層は，末尾のトークンにおける第 32 層の出力を正規化したベクトル $\boldsymbol{r}$ に，各行が語彙中の一つのトークンに対応する重み行列を掛け，スコアの最も高いトークンを選ぶ．$\boldsymbol{r}$ は第 16 層以降の計算で $\boldsymbol{h}$ から定まる．そこで，$\boldsymbol{h}$ の微小変化に対する $\boldsymbol{r}$ の変化率を並べたヤコビ行列 $\boldsymbol{J}$[6] と，$\boldsymbol{r}$ の空間の単位ベクトルである方向 $\boldsymbol{u}$ を用い，相対感度を $e = \|\boldsymbol{J}^{\top}\boldsymbol{u}\|\,\|\boldsymbol{h}\|/\|\boldsymbol{r}\|$ とする．e は，$\boldsymbol{h}$ を相対的に 1%動かすと $\boldsymbol{r}$ が $\boldsymbol{u}$ 方向へ最大で何%動くかを表す．$\boldsymbol{u}$ には，回答の候補の先頭トークンに対応する重み行列の行の，上位 m 個の主成分を用いる．主成分は候補間のスコア差を最も変える方向なので，e が大きいほど回答の選択が $\boldsymbol{h}$ に依存する．e は m 本の方向と評価データの 64 問で平均した．

表 1: 評価結果（3 回の学習の平均．± は標準偏差）

	baseline	**proposal**
正解率（%）	53.54±0.57	53.49±0.31
読み取り精度（%）	82.9	**95.9**
e（$m = 8$）	0.4023	**0.2883**
e（$m = 128$）	0.2415	**0.1973**

3.2 結果

表 1 に評価結果を示す．両手法の正解率の差は平均 −0.06 ポイントであり，95%信頼区間は 0 を含む．一方，proposal の読み取り精度は 13.0 ポイント高く，相対感度 e は $m = 8$, 128 のいずれでも 18–28%低い．よって，タスク署名の情報は内部表現から読み取りやすくなったものの，回答の生成がタスク署名の情報により強く依存するとは言えない．

4 おわりに

本稿では，回答に至るまでの手続きが同じ質問同士の内部表現を近づける，タスク類似性に基づく内部表現整合学習を提案した．

参考文献

[1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.

[2] A. Marafioti *et al.*, “SmolVLM: Redefining Small and Efficient Multimodal Models,” arXiv:2504.05299, 2025.

[3] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.

[4] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.

[5] Y. Elazar *et al.*, “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” *TACL*, 2021.

[6] W. Gurnee *et al.*, “Verbalizable Representations Form a Global Workspace in Language Models,” *Transformer Circuits Thread*, 2026.

東京都立大学大学院 システムデザイン研究科
情報科学域 杉村研究室
〒*191–0065* 東京都日野市旭が丘 *6-6*
E-mail: nakano-tomoharu@ed.tmu.ac.jp