タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴 † 杉村 大輔 †

Tomoharu Nakano† Daisuke Sugimura†

† 東京都立大学

†Tokyo Metropolitan University

Abstract: 視覚言語モデル（VLM）は画像とテキストを包括的に理解するモデルであり，視覚的質問応答などに応用されている．VLM の内部表現は，答えが同じ質問でも，画像の違いに伴い大きく変わることがある．これは，「見つける」,「たどる」,「答える」といった人間が回答を行う手続きの特徴について，VLM が一貫した内部表現を獲得していない可能性を示唆する．そこで本研究では，回答の手続きを各段階の操作の名前の並びとして明示的に扱い，手続きが一致する質問同士の内部表現を近づける，タスク類似性に基づく内部表現整合学習を検討する．実験の結果，類似タスクにおける内部表現の一貫性は回答の正解率には大きくは寄与しないことが確認できた．

1 はじめに

視覚言語モデル（Vision-Language Model; VLM）は画像とテキストを包括的に理解するモデルであり，画像に関する質問に答える視覚的質問応答（Visual Question Answering; VQA）などに応用されている．VLM は一般に，画像を特徴に変換する視覚エンコーダと，画像の特徴と質問文から回答を生成する言語モデル部から成る．

多くの VLM は，正しい回答を出力するように学習される．これはすなわち，VLM の内部表現がどう形成されるべきかは，学習の目的に含まれないということである．Wani ら [1] は，質問に対する回答が正解と変わらない範囲で画像に文字を重ねるなどの加工を施すと，加工の前後で VLM の回答が同じでも，その内部表現が大きく変化していることを示した．このように，回答が同じでも内部表現が大きく変わることから，質問に回答する手順，例えば「見つける」,「たどる」,「答える」といった，人間が画像を見て回答に至るまでの手続きの特徴を，VLM の内部表現は獲得できていない可能性が考えられる．一方，“Who is wearing the dress?” の dress と “What is the boy wearing?” の boy のように，質問中の物体が異なっても，回答の手続きが同じ質問は多い．手続きが同じ質問同士，すなわち類似するタスク間で内部表現が近ければ，VLM は手続きの特徴を物体によらず共通に用いて回答を生成し，回答の正確さが高まると期待できる．

そこで本研究では，手続きが同じ質問同士の内部表現を近づけ，手続きが異なる質問同士を遠ざける，タスク類似性に基づく内部表現整合学習を提案する．これにより，回答に至るまでの手続きの特徴が，質問中の物体によらず一貫した形で内部表現を制約することができる．本稿では，このような VLM の内部表現を整合させることが，VQA にどのように寄与するのか検証する．

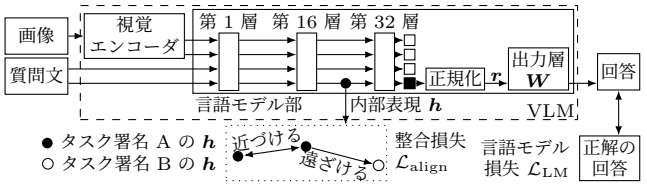


図 1: 提案手法の概要

2 提案手法

2.1 提案手法の概要

図 1 に提案手法の概要を示す．VLM には，SmolVLM-500M-Instruct[2] を用いる．各トークンは自身以前のトークンのみ参照するので，本研究では，画像と質問文のすべてを参照する入力末尾のトークンが第 16 層で持つ 960 次元の潜在特徴 $\boldsymbol{h}$ を，VLM の内部表現として利用する．学習には，言語モデル損失 $\mathcal{L}_{\text{LM}}$ と，本研究で導入する整合損失 $\mathcal{L}_{\text{align}}$ を用いる．これにより，VLM は正しい回答を生成しつつ，類似するタスクのデータ間での内部表現を近づけるよう学習される．

2.2 タスク署名

回答に至る手順が同じかどうかは，VQA のデータセット GQA[3] の各質問に付与された，回答の手順を記述した functional program を用いて判定する．functional program の各段は，select や relate のような操作の名前と，dress や wearing のような操作の対象から成る．本稿では，各段の操作の名前だけを実行順に記号>でつないだ列をタスク署名と呼び，タスク署名が完全に一致する質問同士は手順が同じとみなす．例えば，1 章の二つの質問のタスク署名はともに `select > relate > query`である．

2.3 学習方法

整合損失 $\mathcal{L}_{\text{align}}$ には，画像分類で同じクラスの例の特徴を近づけ，異なるクラスの例の特徴を遠ざける supervised

contrastive loss[4] を採用する．提案手法では，潜在特徴 $\boldsymbol{h}$ に対応するタスク署名をクラスとして扱う．バッチ内の B 個の質問について，i 番目と j 番目の質問の内部表現 $\boldsymbol{h}_i$ と $\boldsymbol{h}_j$ のコサイン類似度を s_{ij}，質問 i とタスク署名が一致する他の質問の集合を $P(i)$ とし，次式で計算する．

$$\mathcal{L}_{\text{align}} = \frac{1}{B}\sum_{i=1}^{B}\Big[\log\sum_{j\neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|}\sum_{p\in P(i)}\frac{s_{ip}}{\tau}\Big] \quad (1)$$

ここで，τ は学習可能な温度パラメータである．

言語モデル損失 $\mathcal{L}_{\text{LM}}$ は，正しい回答を生成するように制約する交差エントロピーである．VLM は，λ を重みとする二つの損失の和 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda\mathcal{L}_{\text{align}}$ を最小化するよう学習される．

3　実験

3.1　実験概要

学習には，GQA が学習用に配布する `train_balanced` から 942,116 問を用いた．各バッチは，無作為に選んだ 16 種のタスク署名から各 2 問，計 32 問とした．VLM のパラメータは，バッチごとに，学習データの問数を 32 で割った 29,441 回更新した．比較手法は，$\lambda = 0$ とし，言語モデル損失のみを用いて学習した baseline と，$\lambda = 0.1$ とした提案手法の proposal の二つである．

学習に用いない `testdev_balanced` の 12,578 問に対し，三つの指標を用いて評価した．第一の指標は，GQA 公式の評価プログラムによる正解率である．第二の指標は読み取り精度であり，潜在特徴 $\boldsymbol{h}$ からタスク署名を予測する線形分類器を 10 問以上あるタスク署名の問の約半数で学習し，残りで測った正解率である．第三の指標は相対感度 e である．線形分類器で読み取れる情報が回答の生成に用いられるとは限らない [5] ため，回答の生成が潜在特徴 $\boldsymbol{h}$ に依存する度合いを測る．回答は 1 トークンずつ生成され，以降は最初のトークンに続けて決まるので，最初のトークンに着目する．入力末尾のトークンの第 32 層の出力を正規化したベクトル $\boldsymbol{r}$ を考える．出力層は，各行が語彙中の一つのトークンに対応する重み行列 $\boldsymbol{W}$ を $\boldsymbol{r}$ に掛け，各トークンの出現確率を計算する．そして，計算された出現確率が最も高いトークンを推論結果として出力する．評価データの正解の最初のトークン 1,085 種を候補と呼ぶ．各候補の出現確率は，$\boldsymbol{W}$ の対応する行と $\boldsymbol{r}$ の内積から計算される．そのため，$\boldsymbol{W}$ の各行の差，すなわち対応する候補間における変換作用の違いが最も大きい方向に $\boldsymbol{r}$ が変化すると，出力される候補もまた変化しやすい．そこで，出力される候補の変化の度合いを調べるために，$\boldsymbol{r}$ の変化の方向 $\boldsymbol{u}$ を考える．ここでは，候補に対応する $\boldsymbol{W}$ の行の上位 m 個の主成分に対応する主成分ベクトルの方向を採用する．$\boldsymbol{r}$ は第 16 層より後の層および正規化で $\boldsymbol{h}$ により表現されるので，

表 1: 評価結果（3 回の学習の平均．± は標準偏差）

	baseline	**proposal**
正解率（%）	53.54±0.57	53.49±0.31
読み取り精度（%）	82.9	**95.9**
相対感度 $\bar{e}$（$m = 8$）	0.4023	0.2883
相対感度 $\bar{e}$（$m = 128$）	0.2415	0.1973

相対感度は，$\boldsymbol{h}$ の微小な変化に対する $\boldsymbol{r}$ の変化率を並べたヤコビ行列 $\boldsymbol{J}$ を用いて定義できる．ここで，$\boldsymbol{J}$ の (k,l) 成分は $\partial r_k/\partial h_l$ である．$\boldsymbol{h}$ に微小な変化 $\boldsymbol{\delta}$ を加えると，$\boldsymbol{r}$ の $\boldsymbol{u}$ 方向の成分は一次近似することで $\boldsymbol{u}^\top\boldsymbol{J}\boldsymbol{\delta}$ 変化する．すなわち，その大きさは最大で $\|\boldsymbol{J}^\top\boldsymbol{u}\|\,\|\boldsymbol{\delta}\|$ となる．よって，$e = (\|\boldsymbol{J}^\top\boldsymbol{u}\|\,\|\boldsymbol{\delta}\|/\|\boldsymbol{r}\|)/(\|\boldsymbol{\delta}\|/\|\boldsymbol{h}\|) = \|\boldsymbol{J}^\top\boldsymbol{u}\|\,\|\boldsymbol{h}\|/\|\boldsymbol{r}\|$ と与えられる．すなわち，e が大きいほど，$\boldsymbol{h}$ のわずかな変化に伴い回答が変わりやすいことを意味する．評価では，m ごとに，m 個の $\boldsymbol{u}$ と評価データの 64 問の全組で e を平均した $\bar{e}$ を用いた．

3.2　結果

表 1 に評価結果を示す．両手法の正解率の差は平均 -0.06 ポイントで，95%信頼区間は 0 を含むので，正解率に有意な差はない．一方，proposal の読み取り精度は 13.0 ポイント高く，類似する手続きの特徴が一貫した形で内部表現に表れた．また，proposal の相対感度 $\bar{e}$ は $m = 8$，128 のいずれでも 18–28%低く，回答の選択が潜在特徴 $\boldsymbol{h}$ に依存する度合いは下がった．これは，内部表現に表れた手続きの特徴が回答の生成に十分用いられていないことを示唆する．以上の結果より，提案手法は正解率を保ったまま手続きの特徴を内部表現に持たせられるが，回答の性能の向上には至らなかった．正解率を高めるには，手続きの特徴を回答の生成に用いる工夫が必要になると考えられる．

4　おわりに

本稿では，回答に至るまでの手続きが同じ質問同士の内部表現を近づける，タスク類似性に基づく内部表現整合学習を提案した．

参考文献

[1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.

[2] A. Marafioti *et al.*, “SmolVLM: Redefining Small and Efficient Multimodal Models,” arXiv:2504.05299, 2025.

[3] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.

[4] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.

[5] Y. Elazar *et al.*, “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” *TACL*, 2021.

東京都立大学大学院 システムデザイン研究科
情報科学域 杉村研究室
〒*191–0065* 東京都日野市旭が丘 *6-6*
E-mail: nakano-tomoharu@ed.tmu.ac.jp