

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

杉村 大輔[†]

Tomoharu Nakano[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) など多くのタスクに応用されている。一方で、入力の変換で答えは同じでも内部表現が大きく変わることが知られており、解き方 (タスク構造) が同じ別々の質問の内部表現が近いことは未解明である。本研究では、タスク構造を署名として形式化し、署名が一致する質問間で内部表現を近づけるタスク類似性に基づく内部表現整合学習を検討する。これにより内部表現がタスク構造に沿って整い、答えの生成に使われるようになると期待できる。この仮説を検証した結果、正解率をほとんど変えずに内部表現から解き方を大きく読み取りやすくなった一方で、モデルはそれを答えの生成に使うようにはならず、依存はむしろ下がること示唆された。

1 はじめに

視覚言語モデル (Vision-Language Model, VLM) は、画像とテキストを入力としてテキストを出力するモデルであり、画像についての質問に答える視覚的質問応答 (Visual Question Answering, VQA) をはじめ多くのタスクに応用されている。VLM は、画像を特徴に変換する視覚エンコーダと、その特徴と質問文を読んで答えを生成する言語モデル部から成る。言語モデル部は多数の層から成り、各層は処理の途中の情報をベクトルとして保持する。本稿ではこのベクトルを内部表現と呼ぶ。

VLM は出力の正解率を最適化するように学習されるため、内部表現がどう組織されるかは学習の目的に含まれず、出力を見るだけでは内部の様子は分からない。実際に Wani ら [1] は、画像に正解を変えない加工 (平行移動や文字の重ね書き) を施すと、答えは変わらないのに内部表現が大きく変化する場合がありますを示した。ただし、扱われたのは同じ入力を加工したときの変化であり、別々の質問の内部表現どうしの関係は調べられていない。VQA には、“What is the man holding?” と “What is the boy wearing?” のように、問われる対象も答えも異なるが、対象を選び、関係をたどり、属性を答えるという解法 (タスク構造) が同じ質問が多数ある。同じ解法の質問の内部表現が互いに近い、また近づければ答えの生成に解法が用いられるようになるかは分かっていない。

そこで本稿では、同じタスク構造を持つ質問どうしの内部表現を明示的に近づける、タスク類似性に基づく内部表現整合学習を提案する。提案手法では、VQA データセット GQA[2] の各質問に付与された解法の手順からタスク署名 (2.1 節. 以下、署名) を定め、署名が一致する質問の内部表現を近づけ、一致しない質問の内部表現を遠ざける整合損失を通常の学習に加える。これにより内部表現がタスク構造に沿って整い、モデルが答えの生成にその構造

を用いるようになると期待できる。

ただし、この期待の検証には、ある性質が内部表現から線形分類器 (プロンプト) で読み取れることと、モデルがその性質を答えの計算に用いていることが別である [3] ことに注意が要る。Elazar ら [4] は言語モデルの内部表現から既にある性質を除いて語予測への影響を見たが、本稿は逆に、性質を損失で内部表現に付与したうえで、それが用いられるかを問う。そのため、正解率に加えて、プロンプトで内部表現から署名を読み取れる精度と、答えの生成がその内部表現に依存する度合い (整合損失を適用した内部表現を微小に動かしたとき答えのスコアがどれだけ動くかという感度) の両方を測る。

評価実験の結果、提案手法は正解率をほとんど変えずに内部表現から署名を読み取れる精度を大きく高めたが、答えの生成が整合損失を適用した内部表現に依存する度合いはむしろ低下した。本稿の貢献は、読み取れることと用いられることが一致しない事例を、性質を除くのでなく加えることで作って示した点にある。

2 提案手法

図 1 に提案手法の概要を示す。本稿では VLM として SmolVLM-500M-Instruct[5] (言語モデル部 32 層、内部表現の次元 $H = 960$) を用いる。提案手法は、言語モデル部の中間層において質問を読み終えた位置の内部表現を取り出し、バッチ内で署名が同じ質問の内部表現を近づけ、署名が異なる質問の内部表現を遠ざける整合損失を、答えの生成に対する通常の損失に加えて学習する。




図 1: 提案手法の概要

2.1 タスク署名

GQA の各質問には、答えに至る手順を演算子の列として記述した functional program が付与されている。例えば “Who is wearing the dress?” の program は、ドレスを選び (select), それを着ている人物へ関係性をたどり (relate), その名前を答える (query) の 3 段から成る。本稿では、program から引数を除いた演算子の列 `select > relate > query` をタスク署名と呼び、署名が一致する質問対を、内部表現を近づける正例対とする。引数まで一致を求めると正例対がほとんど同じ質問になるため、引数は除く。例えば “What is the boy wearing?” は上の質問と同じ署名を持ち、“What color is the cup?” (`select > query`) は異なる署名を持つ。なお、GQA の質問文は program から自動生成されるため、質問文の言い回しと署名は関連する。この交絡は 3.2 節で切り分ける。

2.2 整合損失

整合損失の目的は、同じ署名を持つ質問の内部表現を互いに近づけ、異なる署名を持つ質問の内部表現を遠ざけることである。この目的には、同じラベルを持つ複数の例を同時に引き寄せ、異なるラベルの例を遠ざける損失として画像分類で確立した supervised contrastive loss[6] が適する。ラベルを署名とすれば、この損失が小さくなることは求める性質が内部表現に備わることに他ならないためである。バッチ内の B 件の内部表現 $h_i \in \mathbb{R}^H$ と署名 y_i ($i = 1, \dots, B$) に対し、 $z_i = h_i / \|h_i\|_2$, $s_{ij} = z_i^\top z_j$, $P(i) = \{j \neq i \mid y_j = y_i\}$ とおき、整合損失を

$$\mathcal{L}_{\text{align}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \left[\log \sum_{j \neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|} \sum_{p \in P(i)} \frac{s_{ip}}{\tau} \right] \quad (1)$$

と定める ($\mathcal{I} = \{i \mid P(i) \neq \emptyset\}$)。第 1 項はバッチ内の全質問との類似度、第 2 項は同じ署名の質問との類似度であり、その差を小さくすることが同じ署名だけを相対的に近づけることにあたる。温度 τ は学習可能とし、初期値を 0.07 とする。学習全体の目的関数は $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ であり、 $\mathcal{L}_{\text{LM}}$ は答えのトークンに対する通常の交差エントロピー、 λ は整合損失の重みである。

2.3 整合損失を適用する内部表現

整合損失は、言語モデル部の中間にあたる第 16 層において、質問を読み終えて答えを書き出す直前の位置の内部表現に適用する。言語モデル部の各位置は自分より前の位置しか参照できないため、画像と質問文の両方を読み終えているのはこの位置だけであり、答えの先頭トークンのスコアもこの位置の処理から計算される。したがって、ここに付与した構造は答えの生成に届きうる。原論文 [6] と異なり、内部表現を低次元に写す学習可能な射影は挟まない。射影があると、内部表現を変えずに射影だけを変えて損失を下げられるためである。

3 実験

3.1 実験設定

GQA の `train_balanced` (正例対を組めない 884 問を除く 942,116 問) で 1 エポック学習する。バッチは正例対を組める署名から一様に 16 署名を選び各 2 問ずつの 32 問とし、1 エポックは 29,441 バッチ、学習率は 10^{-5} である。次の 3 群を 3 つの乱数種で学習する。整合損失を用いない baseline ($\lambda = 0$)、署名をラベルとする proposal ($\lambda = 0.1$)、 λ と損失の形は同じままバッチ内でラベルを無作為に並べ替える ablation である。並べ替えはラベルの分布と正例対の数を保ったまま意味だけを取り除くので、proposal が baseline とも ablation とも異なるとき、その差はラベルの意味に帰属できる。ablation の内部表現は互いの類似度 s_{ij} が 0.99 を超えるまで集まるが、署名の読み取り精度は baseline の水準を保つ (表 1)。評価は `testdev_balanced` の 12,578 問で行い、3 乱数種の平均を報告する。正解率の群間差は乱数種を対にした t 検定の 95% 信頼区間で判定し、他の量は乱数種ごとの差の符号の一致で見る。

3.2 署名の読み取り精度

整合損失を適用した内部表現から署名を予測する線形プロープの正解率を読み取り精度と呼ぶ。10 問以上ある 145 署名・10,990 問を、当てはめ用と評価用に半分ずつ分けて測る。2.1 節の交絡を切り分けるため、二つの対照を置く。言い回しプロープ (表 1 の言い回し) は、内部表現の代わりに質問文の語の有無を入力とする同じ線形分類器であり、質問文の語だけで当たる水準を示す。書き出し分離は、先頭 4 語が同じ質問を同じ側に寄せる分割であり、評価用の質問の書き出しは必ず未見となる。

表 1 のとおり、提案手法により読み取り精度は +13.0pt 上がり、ablation では上がらないので、増分はラベルの意

表 1: 署名の読み取り精度と正解率 (3 乱数種の平均)

	読み取り精度		正解率
	通常	書き出し分離	
baseline	82.9%	80.9%	53.54 ± 0.57
proposal	95.9%	95.4%	53.49 ± 0.31
ablation	81.0%	78.6%	53.57 ± 0.25
言い回し	69.7%	66.1%	—

表 2: 答えを決める方向への相対感度 (3 乱数種の平均)

	$m = 8$	$m = 32$	$m = 128$
baseline	0.4023	0.2997	0.2415
proposal	0.2883	0.2341	0.1973
ablation	0.3833	0.2972	0.2419

味に帰属する。言い回しプロンプトは書き出し分離で精度を落とすが proposal はほとんど落ちず、増分は+14.5pt とむしろ広がるので、増分は質問文の言い回しでは説明できない。上がる向き自体は損失の定義から予想されるので、確かめたのは増分の帰属である。

3.3 正解率

各ステップで最も確からしい語を選ぶ貪欲デコードで答えを生成し、GQA 公式の評価器で採点する (表 1 右列)。proposal と baseline の差は平均 -0.06 、95%信頼区間 $[-1.81, +1.70]$ であり、0 を含む。低下は大きくとも 1.81pt であり、正解率の面での代償はほとんど無い。

3.4 整合損失を適用した内部表現への依存

答えの生成が第 16 層の内部表現に依存する度合いを、1 章で述べた感度で測る。内部表現を除去して性能の低下を見る方法を採らないのは、除去された働きを別の層が補償する自己修復 [7] が知られており、性能が変わらないことが用いられていないことを意味しないためである。答えの先頭トークンに対応する出力層の行を中心化し、その上位 m 本の主成分 U_m を、答えどうしのスコア差を最も動かす方向とする。 U_m の各列 u について、第 16 層のベクトル h から最終層の同じ位置のベクトル r へのヤコビ行列 J を用いて [8]、1 章の感度を相対感度 $e = \|J^T u\| \|h\| / \|r\|$ として求める。これは第 16 層を相対的に 1%動かしたとき最終層が u 方向へ何%動くかを表し、 m 本の方向と評価データ 64 問で平均する (表 2)。

proposal の相対感度は、乱数種ごとに baseline との比をとって平均すると 18-28%下がり、3 乱数種すべてで符号が揃う。ablation では下がらない。したがって低下はラベルの意味に帰属し、答えの生成は整合損失を適用した内部表現に以前より頼らなくなった。3.2 節の読み取り精度の増分は、署名が答えの生成に用いられるようになったこ

とを意味しない。ただし相対感度は一次近似の量であり、言えるのは依存が下がったことまでである。

4 むすび

本稿では、同じタスク構造を持つ質問どうしの内部表現を近づける、タスク類似性に基づく内部表現整合学習を提案した。評価実験により、提案手法は正解率をほとんど変えずに内部表現から署名を読み取れる精度を大きく高める一方で、答えの生成がその内部表現に依存する度合いをむしろ下げたことを示した。これは、読み取れることと用いられることが一致しない事例である。結果は単一のモデルとデータセットで得たものであり、今後は答えの型のラベルで整合して効果が署名に固有かを確かめ、 λ と層を変えて結果の及ぶ範囲を検証する。

参考文献

- [1] F. A. Wani et al.: “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] D. A. Hudson and C. D. Manning: “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” CVPR, 2019.
- [3] Y. Belinkov: “Probing Classifiers: Promises, Shortcomings, and Advances,” Computational Linguistics, vol. 48, no. 1, 2022.
- [4] Y. Elazar et al.: “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” TACL, vol. 9, 2021.
- [5] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [6] P. Khosla et al.: “Supervised Contrastive Learning,” NeurIPS, 2020.
- [7] T. McGrath et al.: “The Hydra Effect: Emergent Self-repair in Language Model Computations,” arXiv:2307.15771, 2023.
- [8] W. Gurnee et al.: “Verbalizable Representations Form a Global Workspace in Language Models,” Transformer Circuits Thread, 2026.