

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

Tomoharu Nakano[†]

杉村 大輔[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) などに応用されている。VLM の内部表現は、回答が変わらない場合でも、入力の違いで大きく変わることがある。これは、質問に回答する手順の情報が、内部表現に一貫した形で保持されていない可能性を示す。そこで本研究では、回答の手順を「見つける」「たどる」「答える」のような操作の名前の並び (タスク署名) で表し、タスク署名が一致する質問同士の内部表現を近づける、タスク類似性に基づく内部表現整合学習を検討する。これにより手順の情報が回答の生成に用いられることを期待した。検証の結果、提案手法により、正解率は有意に変わらずにタスク署名の読み取り精度が大きく高まる一方、回答の生成が内部表現に依存する度合いが下がることが示唆された。

1 はじめに

視覚言語モデル (Vision-Language Model; VLM) は、画像とテキストを入力として、入力に応じた出力を生成するモデルであり、画像についての質問に答える視覚的質問応答 (Visual Question Answering; VQA) などに応用されている。VLM は一般に、画像を特徴に変換する視覚エンコーダと、画像の特徴と質問文から回答を生成する言語モデル部から成る。本稿では、言語モデル部の各層が表現する潜在特徴を内部表現と呼ぶ。

多くの VLM は正しい回答を出力するよう学習され、内部表現がどう形成されるべきかは学習の目的に含まれない。Wani ら [1] は、質問の正解が変わらない範囲で画像に文字を重ねるなどの加工を施すと、加工の前後で VLM の回答が同じでも、その内部表現の変化が、無関係な画像同士の内部表現の違いに近い大きさになる場合があることを示した。すなわち、回答が変わらなくても、内部表現が変わらないとは限らない。

このように内部表現が入力の違いで大きく変わる場合、質問に回答する手順の情報が内部表現に一貫した形で保持されているかは明らかでない。ここで回答の手順とは、質問に回答するために画像に対して行う操作の並びである。例えば “Who is wearing the dress?” と “What is the boy wearing?” には、それぞれ dress と boy を見つけ、wearing の関係で結ばれた相手をたどり、その名前を答えることで回答できる。本研究では、このように回答の手順が同じ質問同士の、タスクが類似しているとみなす。

そこで本稿では、タスク類似性に基づく内部表現整合学習を提案する。これを実現するために、手順が同じ質問同士の内部表現を近づけ、手順が異なる質問同士の内部表現を遠ざける整合損失を、正しい回答を出力させるための損失に加えて導入する。これにより、回答の手順の情報が、dress や boy のような質問中の物体によらず一貫した形で内部表現

に含まれ、言語モデル部による回答の生成の品質に寄与することが期待される。

2 提案手法

2.1 提案手法の概要

図 1 に提案手法の概要を示す。VLM には SmolVLM-500M-Instruct[2] を用いる。32 層の言語モデル部は、画像の特徴と質問文をトークンの列として受け取る。注意機構により、各トークンは列の中で自身以前のトークンだけを参照する。よって、画像と質問文のすべてを参照するのは、回答を生成する直前の末尾のトークンだけである。本稿では、末尾のトークンの第 16 層における 960 次元のベクトルを内部表現 h とする。学習では、バッチ内の質問の h 同士から整合損失 $\mathcal{L}_{\text{align}}$ を、VLM が生成した回答と正解の回答から言語モデル損失 $\mathcal{L}_{\text{LM}}$ を計算し、両者の重み付き和を最小化するよう VLM を更新する。これにより、VLM は正しい回答を生成しつつ、手順が同じ質問同士の h を近づけるよう学習される。




図 1: 提案手法の概要

2.2 タスク署名

提案手法では、手順が同じ質問かどうかをタスク署名で判定する。VQA のデータセット GQA[3] の各質問には、回答の手順を記述した functional program が付与されている。functional program の各段は、select や relate のような操作の名前と、dress や wearing のような操作の対象から成る。例えば “Who is wearing the dress?” の functional program は、dress を見つける (select)、wearing の関係で人物へたどる (relate)、人物の名前を答える (query) の 3 段から成る。本稿では、各段の操作の名前だけを順に並べた列をタスク署名と呼び、タスク署名が完全に一致する質問同士を手順が同じ質問とみなす。この例のタスク署名は select > relate > query である。functional program から対象を除く理由は、対象まで含めるとタスク署名が一致する質問が対象も同じ質問に限られ、対象が異なり手順が同じ質問同士を近づけられないためである。

2.3 学習方法

提案手法では、整合損失の重みを λ とした全体の損失 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ を最小化する。整合損失 $\mathcal{L}_{\text{align}}$ には、画像分類で同じクラスの例の特徴を近づけ、異なるクラスの例の特徴を遠ざける supervised contrastive loss[4] を、クラスをタスク署名として $\mathbf{h}$ に適用する。バッチ内の B 間について、質問 i と j の $\mathbf{h}$ のコサイン類似度を s_{ij} 、質問 i とタスク署名が一致する他の質問の集合を $P(i)$ とし、

$$\mathcal{L}_{\text{align}} = \frac{1}{B} \sum_{i=1}^B \left[\log \sum_{j \neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|} \sum_{p \in P(i)} \frac{s_{ip}}{\tau} \right] \quad (1)$$

とする。第 1 項は他の全質問との類似度を、第 2 項はタスク署名が一致する質問との類似度を表す。この損失は、バッチ内の各質問について、後者を前者より高めるほど小さくなる。 τ は類似度の尺度を決める学習可能な温度であり、初期値を 0.07 とする。元の手法 [4] は特徴を学習可能な射影で写してから損失を計算するが、提案手法は射影を介さず $\mathbf{h}$ に直接適用する。射影を介すと、 $\mathbf{h}$ を変えずに射影だけを変えて損失を下げられるためである。言語モデル損失 $\mathcal{L}_{\text{LM}}$ は、正しい回答を生成させるための交差エントロピーである。VLM は回答の文字列を、次のトークンの確率を出力しながら 1 トークンずつ生成する。 $\mathcal{L}_{\text{LM}}$ は、正解の回答の各トークンを正解ラベルとし、VLM がそのトークンに与えた確率の負の対数を平均したものである。

3 実験

3.1 実験概要

提案手法の効果を調べるため、3 つの比較手法で VLM を学習し、評価する。学習には、GQA の学習用データのうち回答の偏りを緩めた train.balanced の 942,116 問を用いる。各バッチは、無作為に選んだ 16 種のタスク署名から各 2 問、計 32 問とする。更新回数は、学習データの問数を 32 で割った 1 エポック分とする。比較手法は、baseline, proposal, ablation の 3 つである。baseline は $\lambda = 0$ とし、整合損失を用いない。proposal は提案手法であり、 $\lambda = 0.1$ とする。ablation は、proposal で生じる変化が、回答の手順に基づいて内部表現を近づけたことによるのか、整合損失を加えたこと自体によるのかを区別するために設ける。ablation では、各バッチの 32 問の間でタスク署名を無作為に入れ替えてから、proposal と同じく整合損失を求める。入れ替えたタスク署名は、バッチ内での種類と数が元と同じだが、回答の手順とは無関係になる。3 つの比較手法のそれぞれで、初期値やデータの順序を決める乱数の種を 3 通り変えて学習し、平均を示す。

評価には学習に用いない testdev.balanced の 12,578 問を用い、3 つの指標を測る。第 1 の指標は正解率であり、生成の各ステップで最も確率の高いトークンを選んで作った回答を、GQA 公式の評価プログラムで採点して求める。

第 2 の指標はタスク署名の読み取り精度であり、内部表現 $\mathbf{h}$ からタスク署名を予測する線形分類器（線形プローブ）の正解率とする。読み取り精度は、タスク署名の情報が $\mathbf{h}$ から線形に取り出せるほど高い。線形分類器を用いるのは、分類器自身の計算で情報を作り出さず、 $\mathbf{h}$ にそのまま表れている情報を測るためである。評価データのうち 10 問以上あるタスク署名の 10,990 問を二分し、一方で線形プローブを学習し、他方で読み取り精度を測る。

第 3 の指標は相対感度である。線形プローブで読み取れる情報が回答の生成に用いられるとは限らない [5] ため、回答の生成が $\mathbf{h}$ に依存する度合いを測る。回答の先頭トークンは末尾のトークンの最終層のベクトル $\mathbf{r}$ から選ばれるので、 $\mathbf{h}$ を動かしたときに $\mathbf{r}$ が回答の選択を変える方向へどれだけ動くかを見れば、依存の度合いがわかる。そこで、 $\mathbf{h}$ から $\mathbf{r}$ へのヤコビ行列 $\mathbf{J}$ [6] を用い、方向 $\mathbf{u}$ に対する相対感度を $e = \|\mathbf{J}^\top \mathbf{u}\| \|\mathbf{h}\| / \|\mathbf{r}\|$ とする。 e は、 $\mathbf{h}$ を

表 1: 各比較手法の評価結果（正解率の $\pm$ は標準偏差）

	baseline	proposal	ablation
正解率	53.54 $\pm$ 0.57	53.49 $\pm$ 0.31	53.57 $\pm$ 0.25
読み取り精度	82.9%	95.9%	81.0%
e ($m = 8$)	0.4023	0.2883	0.3833
e ($m = 32$)	0.2997	0.2341	0.2972
e ($m = 128$)	0.2415	0.1973	0.2419

相対的に1%動かすと r が u 方向へ最大で何%動くかを表し、大きいほど回答の選択が h に依存する。方向 u には、出力層の重み行列から回答の候補の先頭トークンに対応する行を取り出し、各列の平均を引いて主成分分析を行って得た、上位 m 個の主成分を用いる。これらは、回答の候補の間でスコアの変化が最も異なる方向である。 e は m 本の方向と評価データ 64 間で平均する。

3.2 結果

表 1 より、正解率の proposal と baseline の差は平均 -0.06 ポイントで、差の 95%信頼区間 $[-1.81, +1.70]$ は 0 を含む。proposal の読み取り精度は baseline より 13.0 ポイント高い。proposal の相対感度 e は、乱数の種ごとの baseline 比の平均で 18–28%低く、すべての m と乱数の種で低下した。

ablation では、読み取り精度は向上せず、相対感度の変化は同じ平均で -4.3% から $+0.4\%$ にとどまった。よって、読み取り精度の向上と相対感度の低下は、回答の手順に基づいて内部表現を近づけたことに起因すると考えられる。以上より、タスク類似性に基づく内部表現整合学習によって、タスク署名の情報が内部表現から多く読み取れるようになって、VLM がその情報を回答の生成により多く用いるとは言えない。

4 おわりに

本稿では、GQA の functional program から得たタスク署名に基づき、手順が同じ質問同士の内部表現を近づける、タスク類似性に基づく内部表現整合学習を提案した。実験の結果から、提案手法は正解率を有意に変えずにタスク署名の読み取り精度を大きく高める一方、回答の生成が内部表現に依存する度合いを下げるという示唆が得られた。

参考文献

- [1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [3] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.
- [4] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.
- [5] Y. Elazar *et al.*, “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” *TACL*, 2021.
- [6] W. Gurnee *et al.*, “Verbalizable Representations Form a Global Workspace in Language Models,” *Transformer Circuits Thread*, 2026.