

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

杉村 大輔[†]

Tomoharu Nakano[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) などに応用されている。VLM の内部表現は、答えが同じでも入力の変り方で大きく変わりうる。しかし、推論の手順 (タスク構造) が同じ質問どうしの内部表現が近いことは未解明である。本研究では、タスク類似性に基づく内部表現整合学習を検討する。これは、タスク構造を署名として形式化し、署名が一致する質問の内部表現を近づけるものである。これにより内部表現がタスク構造に沿って整い、答えの生成に用いられると期待できる。検証の結果、正解率をほとんど変えずに署名の読み取り精度は大きく高まったが、答えの生成がその内部表現に依存する度合いはむしろ下がることが示唆された。

1 はじめに

視覚言語モデル (Vision-Language Model, VLM) は、画像とテキストを入力としてテキストを出力するモデルであり、画像についての質問に答える視覚的質問応答 (Visual Question Answering, VQA) などに応用されている。答えを生成する言語モデル部 (図 1) の各層が保持する処理途中のベクトルを、内部表現と呼ぶ。

VLM は出力の正解率を最適化するように学習されるため、内部表現がどう組織されるかは学習の目的に含まれない。実際、Wani ら [1] は、正解を変えない画像の加工で、答えは同じでも内部表現が大きく変わりうることを示した。ただし、これは同じ入力の加工による変化であり、別々の質問どうしの関係は調べられていない。VQA には、“What is the man holding?” と “What is the boy wearing?” のように、対象も答えも異なるが、対象を選び、関係をたどり、属性を答えるという推論の手順が同じ質問が多数ある。本稿ではこの手順をタスク構造と呼ぶ。同じタスク構造の質問どうしで内部表現が近いのか、近づければ答えの生成にタスク構造が用いられるのかは、分かっていない。

そこで本稿では、同じタスク構造を持つ質問どうしの内部表現を近づける、タスク類似性に基づく内部表現整合学習を提案する。VQA データセット GQA[2] の推論の手順の記述からタスク署名 (以下、署名) を定め、署名が一致する質問の内部表現を近づけ、一致しないものを遠ざける整合損失を学習に加える。これにより内部表現がタスク構造に沿って整い、答えの生成に用いられると期待できる。

この期待を確かめるには、ある性質が内部表現から線形分類器 (プローブ) で読み取れることと、モデルがそれを答えの計算に用いることを区別する必要がある。Elazar ら [3] は読み取れる性質を除いても予測がほぼ変わらない例を示したが、本稿は逆に性質を加え、それが用いられるかを問う。そこで正解率に加え、署名の読み取り精度と、答




図 1: 提案手法の概要

えの生成が整合損失を適用した内部表現に依存する度合い (内部表現を微小に動かしたときの答えの感度) を測る。

実験の結果、提案手法は正解率をほぼ変えずに署名の読み取り精度を大きく高めたが、依存の度合いはむしろ低下した。本稿の貢献は、読み取れることと用いられることが一致しない事例を、性質を加える側から示した点にある。

2 提案手法

図 1 に提案手法の概要を示す。VLM には SmolVLM-500M-Instruct[4] (言語モデル部 32 層、内部表現の次元 $H = 960$) を用いる。整合損失は、言語モデル部の中間の第 16 層で、質問を読み終えて答えを書き出す直前の位置の内部表現に適用する。各位置はそれより前しか参照できないため、画像と質問文の両方を読み終え、答えの先頭トークンのスコアを計算するのはこの位置である。したがって、ここに付与した構造は答えの生成に届きうる。

GQA の各質問には、答えに至る手順を記述した functional program が付与されている。program の各段は、演算の種類を表す演算子と演算の対象から成る。例えば “Who is wearing the dress?” は、dress を選び (select), wearing の関係で人物へたどり (relate), 名前を答える (query)。対象を除いて演算子だけを並べた列 (この例で

表 1: 署名の読み取り精度と正解率 (3 乱数種の平均)

	読み取り精度	正解率
baseline	82.9%	53.54 ± 0.57
proposal	95.9%	53.49 ± 0.31
ablation	81.0%	53.57 ± 0.25
言い回し	69.7%	—

は `select > relate > query`) をタスク署名と呼ぶ。対象まで含めると、署名が一致する質問がほぼ同じ質問に限られるためである。GQA の質問文は program から作られるため言い回しと署名は相関するが、その影響は 3 章の対照で確かめる。

整合損失には、画像分類で用いられる supervised contrastive loss[5] を用いる。この損失は同じラベルの例どうしを引き寄せ、異なるラベルの例を遠ざけるものであり、ラベルを署名とすれば、損失が小さいことがそのまま求める性質にあたる。バッチ内の B 件の内部表現 $h_i \in \mathbb{R}^H$ と署名 y_i に対し、 $z_i = h_i / \|h_i\|_2$, $s_{ij} = z_i^\top z_j$, $P(i) = \{j \neq i \mid y_j = y_i\}$ とおき、整合損失を

$$\mathcal{L}_{\text{align}} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \left[\log \sum_{j \neq i} e^{s_{ij}/\tau} - \frac{1}{|P(i)|} \sum_{p \in P(i)} \frac{s_{ip}}{\tau} \right] \quad (1)$$

と定める ($\mathcal{I} = \{i \mid P(i) \neq \emptyset\}$)。温度 τ は学習可能で、初期値は 0.07 とする。図 1 の目的関数の $\mathcal{L}_{\text{LM}}$ は答えのトークンの交差エントロピー、 λ は整合損失の重みである。

3 実験

GQA の `train_balanced` (942,116 問) で 1 エポック学習する。各バッチは、一様に選んだ 16 署名から 2 問ずつ取った 32 問とし、学習率は 10^{-5} とする。比較する群は、整合損失を用いない baseline ($\lambda = 0$)、署名をラベルとする proposal ($\lambda = 0.1$)、 λ と損失の形は proposal と同じままバッチ内でラベルを無作為に並べ替える ablation の 3 つであり、それぞれ 3 つの乱数種で学習する。並べ替えはラベルの分布と同じ署名の組の数を保ったまま意味だけを取り除くので、proposal が baseline と ablation と異なるならば、その差はラベルの意味に帰属できる。評価は `testdev_balanced` の 12,578 問で行い、3 乱数種の平均を報告する。読み取り精度は、内部表現から署名を予測する線形プローブの正解率とし、10 問以上ある 145 署名の 10,990 問を半分ずつ当てはめと評価に用いて測る。言い回しの対照には、内部表現の代わりに質問文の語の有無を入力とする同じ分類器 (言い回しプローブ) を置く。

表 1 のとおり、読み取り精度は提案手法で +13.0pt 上がり、ablation では上がらないので、増分はラベルの意味に帰属する。言い回しプローブは 69.7%にとどまり、proposal は質問文の語で当たる水準を大きく上回る。精度の向上自体は損失の定義から予想され、確かめたのは帰属である。

正解率は、各段で最も確からしい語を選ぶ貪欲デコードの答えを GQA 公式の評価器で採点して求めた。proposal と baseline の差は平均 -0.06 で、乱数種を対にした t 検定の 95%信頼区間 $[-1.81, +1.70]$ は 0 を含む。低下は大きくとも 1.81pt で、正解率の面での代償はほとんど無い。

依存の度合いは相対感度で測る。内部表現を除去して性能を見る方法は、その働きを別の層が補いうるため採らない。答えの先頭トークンに対応する出力層の行を中心化し、その上位 m 本の主成分を答えを決める方向とする。各方向 u について、第 16 層のベクトル h から最終層の同じ位置のベクトル r へのヤコビ行列 $J[6]$ を用いて、相対感度を $e = \|J^\top u\| \|h\| / \|r\|$ と定める。これは h を相対的に 1%動かしたとき r が u 方向へ何%動くかを表す。 m 本の方向と評価データ 64 問で平均した相対感度は、 $m = 8, 32, 128$ の順に、baseline で 0.4023, 0.2997, 0.2415, proposal で 0.2883, 0.2341, 0.1973, ablation で 0.3833, 0.2972, 0.2419 である。

proposal の相対感度は、乱数種ごとの baseline との比の平均で 18–28%低く、3 乱数種すべてで向きが揃う。ablation では下がらないので、低下もラベルの意味に帰属する。答えの生成は整合損失を適用した内部表現に以前より頼らなくなっており、読み取り精度の増分は署名が用いられるようになったことを意味しない。ただし相対感度は一次近似であり、言えるのは依存の低下までである。

4 むすび

本稿では、タスク類似性に基づく内部表現整合学習を提案した。実験では、提案手法は正解率をほぼ変えずに署名の読み取り精度を大きく高めた一方、答えの生成がその内部表現に依存する度合いをむしろ下げた。これにより、読み取れる性質が用いられるとは限らないことを示した。

参考文献

- [1] F. A. Wani et al.: “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] D. A. Hudson and C. D. Manning: “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” CVPR, 2019.
- [3] Y. Elazar et al.: “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” TACL, vol. 9, 2021.
- [4] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [5] P. Khosla et al.: “Supervised Contrastive Learning,” NeurIPS, 2020.
- [6] W. Gurnee et al.: “Verbalizable Representations Form a Global Workspace in Language Models,” Transformer Circuits Thread, 2026.