

タスク類似性に基づく内部表現整合学習が 視覚言語モデルの出力に与える影響

Effects of Task-Similarity-Based Internal Representation Alignment on the Outputs of Vision-Language Models

中野 友晴[†]

杉村 大輔[†]

Tomoharu Nakano[†]

Daisuke Sugimura[†]

[†] 東京都立大学

[†]Tokyo Metropolitan University

Abstract: 視覚言語モデル (VLM) は画像とテキストを包括的に理解するモデルであり、視覚的質問応答 (VQA) などに応用されている。VLM の内部表現は、答えが同じでも入力の変動で大きく変わりうる。しかし、推論の手順が同じ質問同士で内部表現が近いことは明らかでない。本研究では、推論の手順を「見つける」「たどる」「答える」のような操作の名前の並び (タスク署名) で表し、タスク署名が一致する質問同士の内部表現を近づける、タスク類似性に基づく内部表現整合学習を検討する。これにより推論の手順の情報が答えの生成に用いられると期待したが、検証の結果、提案手法は正解率を有意に変えずにタスク署名の読み取り精度を大きく高める一方、答えの生成が内部表現に依存する度合いを下げることで示唆された。

1 はじめに

視覚言語モデル (Vision-Language Model; VLM) は、画像とテキストを入力として、それらに応じた出力を生成するモデルであり、画像についての質問に答える視覚的質問応答 (Visual Question Answering; VQA) などに応用されている。本稿では、VLM のうち答えを生成する言語モデル部の各層が表現する潜在特徴を、内部表現と呼ぶ。

多くの VLM では正解率を高めるよう学習が行われ、内部表現がどう形成されるべきかは学習の目的に含まれない。これに対し Wani ら [1] は、平行移動など質問の正解を変えない加工を画像に施すと、答えは同じでも内部表現が大きく変わりうることを示した。

Wani らは同じ質問での画像加工を扱ったが、異なる質問が同じ推論の手順で解ける場合もある。例えば “Who is wearing the dress?” と “What is the boy wearing?” では、dress と boy を見つけ、wearing の関係で相手をたどって名前を答える。本稿ではこうした質問をタスクが類似した質問と呼ぶ。その内部表現の近さは未解明である。

本稿では、タスク類似性に基づく内部表現整合学習を提案する。VQA データセット GQA[2] の推論の手順の記述から、「見つける」「たどる」「答える」のような操作の名前だけを順に並べた列 (タスク署名) を作り、タスク署名が一致する質問同士の内部表現を近づけ、一致しない質問同士を遠ざける整合損失を導入する。これにより、VLM が推論の手順の情報を答えの生成に用いると期待できる。

2 提案手法

2.1 提案手法の概要

図 1 に提案手法の概要を示す。VLM には SmolVLM-500M-Instruct[3] を用いる。32 層の言語モデル部は画像




図 1: 提案手法の概要

の特徴と質問文をトークンの列として受け取り、各トークンの計算では注意機構によりそれ以前のトークンだけを参照する。よって、画像と質問文のすべてを参照するのは、答えを書き出す直前の末尾のトークンだけである。本稿では、末尾のトークンの第 16 層における 960 次元のベクトルを内部表現 h とし、整合損失を適用する。

2.2 タスク署名

GQA の各質問には、答えを導く手順を記述した functional program が付与されている。functional program の各段は、select や relate のような操作の名前と、dress や wearing のような操作の対象から成る。例えば “Who is wearing the dress?” の functional program は、dress を見つける (select)、wearing の関係で人物へたどる (relate)、人物の名前を答える (query) の 3 段から成る。本稿では、各段の操作の名前だけを順に並べた列 (この例では select > relate > query) をタスク署名と呼び、タスク署名が完全に一致する質問同士をタスクが類似した質問とみなす。1 章の二つの質問は同じタスク署名を持ち、“What color is the cup?” は select > query であり異なる。対象を除くのは、対象まで含めるとタスク署名が一致する質問がほぼ同一の質問に限られ、対象が異なり手順が同じ質問同士を近づけられないためである。

2.3 内部表現整合損失と学習方法

整合損失 $\mathcal{L}_{\text{align}}$ には、ラベルをタスク署名とした supervised contrastive loss[4] を用いる。この損失は、バッチ内の各質問について、タスク署名が一致する質問との内部表現の類似度を、他の全質問との類似度に比べて高めるほど小さくなる。類似度はコサイン類似度とし、類似度の尺度を温度と呼ばれる学習可能なパラメータ τ で調整する。通常の学習では、正解の答えのトークン列に対する交差エントロピー損失 $\mathcal{L}_{\text{LM}}$ を最小化する。提案手法では、整合損失の重みを λ とした全体の損失 $\mathcal{L} = \mathcal{L}_{\text{LM}} + \lambda \mathcal{L}_{\text{align}}$ を最小化するように、VLM のパラメータと τ を学習する。

3 実験

3.1 実験設定

学習には、GQA の学習用データのうち答えの偏りを緩めた `train_balanced` の 942,116 問を用いる。各バッチは、無作為に選んだ 16 種のタスク署名から各 2 問、計 32 問とする。更新回数は、学習データの間数を 32 で割った 1 エポック分とする。学習条件は、整合損失を用いない baseline ($\lambda = 0$)、提案手法の proposal ($\lambda = 0.1$)、ablation である。ablation では、proposal と同じ学習方法で、バッチ内の質問の間でタスク署名を無作為に並べ替えて整合損失を計算する。並べ替えたタスク署名は推論の手順と無関係になるが、種類と数は変わらないため、proposal で生じ ablation で生じない変化は、推論の手順に基づいて内部表現を近づけたことによる。各条件で、初期値やデータの順序を決める乱数の種を 3 通り変えて学習し、平均を示す。

評価には学習に用いない `testdev_balanced` の 12,578 問を用い、3 つの指標を測る。第 1 の指標は正解率であり、生成の各ステップで最も確率の高いトークンを選んで作った答えを、GQA 公式の評価プログラムで採点して求める。

第 2 の指標はタスク署名の読み取り精度であり、内部表現 $\mathbf{h}$ からタスク署名を予測する線形分類器（線形プローブ）の正解率とする。読み取り精度が高いほど、タスク署名の情報が線形に取り出せる形で内部表現に含まれている。プローブは評価データの半数で学習し、残りで測る。

第 3 の指標は相対感度である。プローブで読み取れる情報が答えの生成に用いられるとは限らない [5] ため、答えの生成が $\mathbf{h}$ に依存する度合いを測る。出力層の重み行列から答えの先頭トークンに対応する行を取り出し、各列の平均を引いて主成分分析を行い、上位 m 個の主成分を、答えの候補の間でスコアの変化が最も異なる方向として得る。答えの最初のトークンは末尾のトークンの最終層のベクトル $\mathbf{r}$ から選ばれるので、 $\mathbf{h}$ から $\mathbf{r}$ へのヤコビ行列 $\mathbf{J}$ [6] を用い、方向 $\mathbf{u}$ に対する相対感度を $e = \|\mathbf{J}^\top \mathbf{u}\| \|\mathbf{h}\| / \|\mathbf{r}\|$

表 1: 各学習条件の評価結果（正解率の $\pm$ は標準偏差）

	baseline	proposal	ablation
正解率	53.54 $\pm$ 0.57	53.49 $\pm$ 0.31	53.57 $\pm$ 0.25
読み取り精度	82.9%	95.9%	81.0%
e ($m = 8$)	0.4023	0.2883	0.3833
e ($m = 32$)	0.2997	0.2341	0.2972
e ($m = 128$)	0.2415	0.1973	0.2419

とする。 e は、 $\mathbf{h}$ を相対的に 1% 動かすと $\mathbf{r}$ が $\mathbf{u}$ 方向へ最大で何% 動くかを表し、大きいほど答えの選択が $\mathbf{h}$ に依存する。 e は m 本の方向と評価データ 64 問で平均する。

3.2 結果

表 1 より、proposal の読み取り精度は baseline より 13.0 ポイント高く、ablation の読み取り精度は向上しなかった。よって、この向上は推論の手順に基づいて内部表現を近づけたことによる。正解率の proposal と baseline の差は平均 -0.06 ポイントで、その 95% 信頼区間 $[-1.81, +1.70]$ は 0 を含み、正解率の低下は最大 1.81 ポイントである。

proposal の相対感度 e は、乱数の種ごとの baseline 比の平均で 18–28% 低く、 m と乱数の種のすべての組で低下した。ablation の相対感度はほぼ不変のため、この低下も推論の手順に基づいて内部表現を近づけたことによる。よって、タスク署名の情報が内部表現に含まれても、VLM がそれを答えの生成により多く用いるとは言えない。

4 おわりに

本稿のタスク類似性に基づく内部表現整合学習は正解率を有意に変えずにタスク署名の読み取り精度を大きく高めたが、答えの生成が内部表現に依存する度合いを下げた。

参考文献

- [1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
- [2] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.
- [3] SmolVLM-500M-Instruct, <https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct>
- [4] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.
- [5] Y. Elazar *et al.*, “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” *TACL*, 2021.
- [6] W. Gurnee *et al.*, “Verbalizable Representations Form a Global Workspace in Language Models,” *Transformer Circuits Thread*, 2026.