

視覚言語モデルにおけるタスク類似性に基づく 内部表現整合学習に関する検討

学修番号：26860646

氏名：中野友晴

指導教員：杉村大輔 准教授


研究背景・目的

VLM … 画像と言語を統合的に扱うモデル（画像質問応答などに活用）

- VLM は出力が同じでも内部表現（各層の特徴）が不安定
- 推論過程が同じ「類似タスク」間で内部表現が揃っているかは未解明

→ 内部表現を整合（＝揃える）し性能・信頼性の向上を狙う

目的 類似タスク同士の内部表現を整合させ、性能が上がるかを検証する




関連研究

Same Answer, Different Representations (Wani ら, arXiv 2026) [1]

画像摂動（正解を保つ画像の変換）下で VLM 出力と内部表現を同時計測

- テキスト重畳（画像上に文字を重ねる）で回答変化率 19.2%
- 出力が同じでも内部表現は別画像入力に迫るほど変化

→ 内部の不安定さは信頼性・解釈性の課題（出力からは見えない）



提案手法

「推論過程が同じタスクは内部表現も揃うべき」——仮説を明示的に課す


推論過程が同じタスクの例

“What is the man holding?” ⇔ “What is the boy wearing?”

どちらも「対象を選ぶ → 関係をたどる → 答える」

- 推論過程が同じ質問対を「類似タスク」と定義
- 対照学習 SupCon [2]：同種の表現を近づけ異種を遠ざける学習
- 【狙い】類似タスクの表現を接近・非類似は分離
- VLM 既定の損失 $\mathcal{L}_{LM}$ に、対照損失 SupCon の項を加えて fine-tuning

$$\mathcal{L} = \mathcal{L}_{LM} + \lambda \times \text{SupCon}$$



評価実験

SmoIVLM-500M を GQA で fine-tuning. 整合対象は Text Decoder 16層目（32層中）・プロンプト最終トークンの内部表現

GQA の functional program の演算子列（例：select → relate → query）を「タスク署名」とし、一致を類似タスクとして 3 群で対照実験

群	内容	確認事項
baseline	モデルを GQA で fine-tuning	評価基準
proposal	baseline + 整合（タスク署名）	タスク署名の必要性
ablation	baseline + 整合（署名置換）	整合の影響



指標	baseline	proposal	ablation
accuracy（正解率）	53.64%	52.97%	54.01%
distribution（答え分布のズレ）	2.11	2.29	2.57
separation_d（表現の分離度）	0.67	2.35	0.29

考察

- proposal で分離度が 3.5 倍に増加（0.67 → 2.35）
- 整合操作は正しく機能（仮説の支持ではない）
- proposal で accuracy はほぼ変化せず
- ablation で内部表現を崩壊させても accuracy の悪化なし
- 今回の整合箇所は出力に必須でなく、迂回されうる

今後の展望

① 表現の“ズレ”は実在するか

類似タスクの表現差を学習なしで測定し、整合の可否を判断

② 迂回されない整合箇所の探索

層・位置・部分空間を変え、出力に効く箇所を特定

③ 因果検証と汎化の評価

整合箇所を壊して出力への影響を測り、未知タスクへの汎化も検証

参考文献

[1] F. A. Wani et al., "Same Answer, Different Representations: Hidden instability in VLMs," arXiv preprint arXiv:2602.06652, 2026.

[2] P. Khosla et al., "Supervised Contrastive Learning," in Advances in Neural Information Processing Systems (NeurIPS), vol. 33, 2020, pp. 18661–18673 (arXiv:2004.11362).

[3] D. A. Hudson and C. D. Manning, "GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering," in Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR), 2019, pp. 6700–6709 (arXiv:1902.09506).