P3-15

タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

中野 友晴，杉村 大輔（東京都立大学）

問い

答えに至る手順を視覚言語モデルの内部表現が獲得すれば，正解率は上がるか？

手順の例：女の子を見つける → 持っている物へたどる → 名前を答える

わかったこと

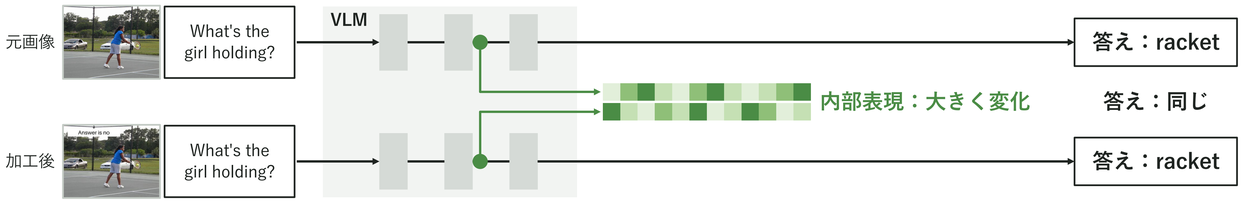
手順の情報は内部表現に強く表れるが，答えの生成には十分使われない

正解率はほとんど変わらず，答えが内部表現に依存する度合いは下がった

1. 背景と問い

- 視覚言語モデル（VLM）：画像と質問文から答えを生成
- 内部表現：VLM が答えを出す前に内部で持つベクトル
- 通常の学習の目的は，答えの正しさだけ
  （内部表現の形は目的に含まれない）

Wani ら[1]の研究
目的 VLM の頑健性を，答えだけでなく内部表現でも評価
方法 意味が変わらない範囲で画像を加工し，
加工の前後で答えと内部表現を比較
結果 答えが同じでも，内部表現が大きく変わる場合あり



→ 一方，人間は画像が加工されても，同じ手順を踏んで答えを導くと考えられる

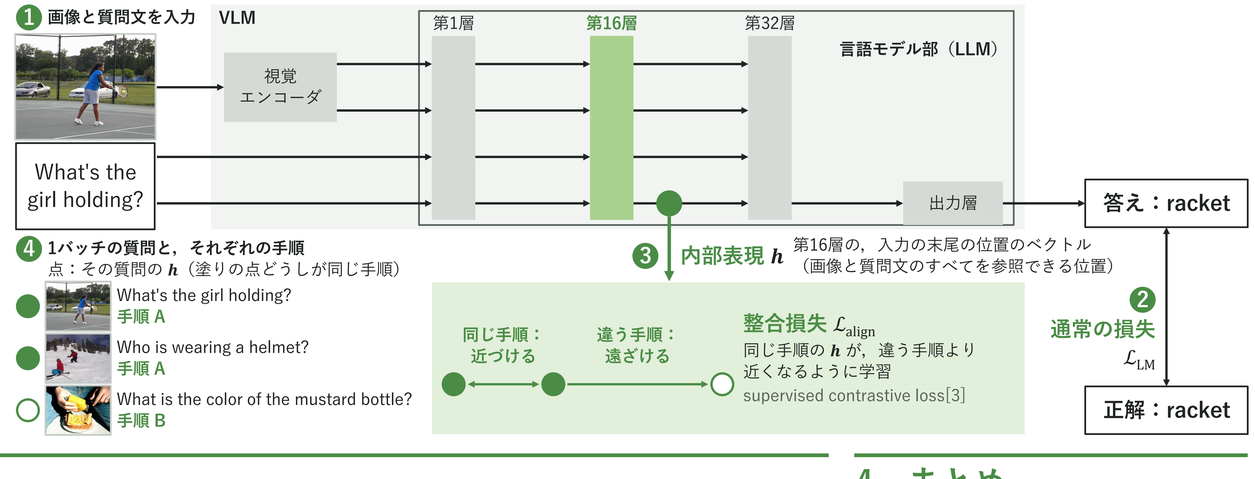
functional program：答えに至る推論の手順を，操作の列で書き下したもの（データセット GQA[2] の各質問に付属）
例 What's the girl holding? → racket



問い このような手順を VLM の内部表現が獲得できれば，正解率は上がるか？

2. 提案手法

キーアイデア **答えに至る手順が同じ質問どうしの内部表現を近づけ，手順が違う質問どうしを遠ざける**
理由 内部表現が，答えに至る手順を備える → 答えはこの内部表現を経て生成されるので，正解率の向上を期待
方法 通常の損失 $\mathcal{L}_{\mathrm{LM}}$ に，整合損失 $\mathcal{L}_{\mathrm{align}}$ を追加：$\mathcal{L} = \mathcal{L}_{\mathrm{LM}} + \lambda \mathcal{L}_{\mathrm{align}}$（$\lambda = 0.1$）
工夫 画像分類で同じ種類の画像を近づける手法[3]を，答えに至る手順が同じ質問に転用
元の手法は表現を小さなネットワークに通してから近づける → 通さず，$\boldsymbol{h}$（下図③）を直接近づける
通すと，$\boldsymbol{h}$ が変わらないまま，小さなネットワークの側だけで損失が下がりうるため



3. 実験

3.1 実験設定

同じ手順の判定
タスク署名（以下，署名）：program から操作の名前だけを並べた列
署名が一致すれば，同じ手順とみなす（操作の対象は見ない）
例 select: girl → relate: holding → query: name
→ **select > relate > query**：2章の図の手順 A（B は **select > query**）

比べる3群 整合の有無と，整合に使う署名だけを変えて学習

■	baseline	整合なし（通常の損失 $\mathcal{L}_{\mathrm{LM}}$ だけ）
■	**proposal**	**質問の署名**
■	ablation	質問と対応しない署名（並べ替え）

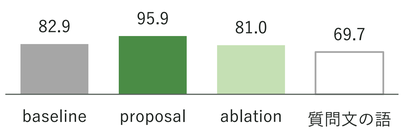
proposal が両方と違えば，手順（署名）による効果

学習と評価
モデル：SmolVLM-500M-Instruct[4]
学習：GQA[2] 942,116問から抽出（1バッチは16署名 × 2問）
評価：12,578問（学習に不使用）．値は乱数種3つの平均（3.3 は5つ）
区間：乱数種を対にした t 検定（対応のある t 検定）の95%信頼区間

3.2 手順の情報は内部表現に表れ，答えに使われるか

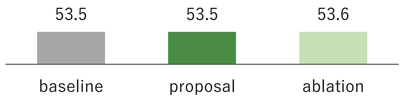
入力：評価データの画像と質問文（加工なし）

読み取り精度（%）
目的 手順の情報が $\boldsymbol{h}$ に表れるかの確認
方法 $\boldsymbol{h}$ から署名を当てる線形分類器の正解率
（10問以上ある署名の問．半数で学習）
比較 質問文の語だけから署名を当てる同じ分類器
（質問文を読むだけで当たる水準）



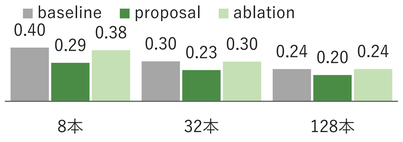
結果 **手順の情報が $\boldsymbol{h}$ に表れた**
proposal だけ上昇．質問文の語の水準も超える
baseline との差： +13.0pt [+11.6, +14.4]

正解率（%）
目的 答えの正確さが上がったかの確認
方法 GQA 公式の評価スクリプト（12,578問）



結果 **3群でほとんど同じ**
baseline との差： −0.06pt [−1.81, +1.70]

相対感度
目的 答えが $\boldsymbol{h}$ に依存する度合いの確認
方法 出力層で答えの語に当たる重みの主成分を
答えを決める方向とする（横軸の本数）
$\boldsymbol{h}$ を1%動かしたとき最終層がその方向に
動く最大の%（近似）を，方向と64問で平均

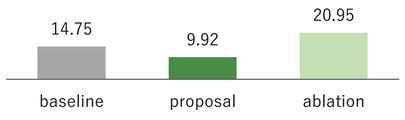


結果 **答えの $\boldsymbol{h}$ への依存が低下**
proposal だけ低下（128本は区間が 0 を含む）
baseline との差： 8本 −28.0% [−44.4, −11.5]
32本 −21.6% [−38.1, −5.2]
128本 −18.0% [−36.4, +0.3]

3.3 画像を加工しても，内部表現は動きにくくなるか

入力：同じ質問文と加工した画像（3.2 と違うのは画像だけ）

動きの比（%）
目的 加工で $\boldsymbol{h}$ がどれだけ動くかの確認
方法 Wani ら[1]の尺度：加工の前後の $\boldsymbol{h}$ の
距離 ÷ 別の画像に替えたときの距離
（加工による動きが別の画像の何%か）
距離の大きさが3群で違うので，比で比べる



結果 **比で見た $\boldsymbol{h}$ の動きが縮小**
proposal だけ低下
baseline との差： −4.82pt [−7.87, −1.77]

加工の例 Wani ら[1]に倣う23通りを全問に適用



答えが変わった問の割合（%）
目的 出力まで変わるかの確認
方法 加工の前後で答えが変わった問 ÷ 全問

結果 **3群でほとんど同じ**
baseline との差： −0.14pt [−0.60, +0.32]

考察 手順の情報は $\boldsymbol{h}$ に強く表れたが，正解率はほとんど変わらず，答えの $\boldsymbol{h}$ への依存は低下

手順の情報は，答えの生成に十分使われていないと考えられる

考察 proposal は $\boldsymbol{h}$ の動き自体が大きい（加工：約3倍，別の画像：約5倍）

**別の画像に比べた $\boldsymbol{h}$ の動き（比）は小さくなったが，
$\boldsymbol{h}$ が動きにくくなったとまでは言えない**

4. まとめ

研究の概要
答えに至る手順が同じ質問の
内部表現を近づける学習を
VLM に追加し，内部表現と
答えの生成への影響を検証

結果
- **読み取り精度**：手順の情報が $\boldsymbol{h}$ に表れた
- **正解率**：3群でほとんど同じ
- **相対感度**：答えの $\boldsymbol{h}$ への依存が低下
- **動きの比**：別の画像に比べた動きが縮小

考察
- 内部表現の形は変わったが，
答えの生成に使われるように
なったとは言えない
- 別の画像に比べた $\boldsymbol{h}$ の動き
（比）は小さくなったが，$\boldsymbol{h}$ が
動きにくくなったとまでは言えない

1モデル・1データセットでの結果
（整合は第16層，$\lambda = 0.1$）

[1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
[2] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.
[3] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.
[4] A. Marafioti *et al.*, “SmolVLM: Redefining Small and Efficient Multimodal Models,” arXiv:2504.05299, 2025.
画像：GQA[2] testdev の問 201593903・201889340・20794339 の画像と，「別の画像」に引いた画像．加工は本研究．