P3-15

タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

中野 友晴，杉村 大輔（東京都立大学）

問い

答えに至る手順を視覚言語モデルの内部表現が獲得すれば，正解率は上がるか？

例　質問：What's the girl holding?
答えに至る手順：女の子を見つける → 持っている物へたどる → それが何かを答える

わかったこと

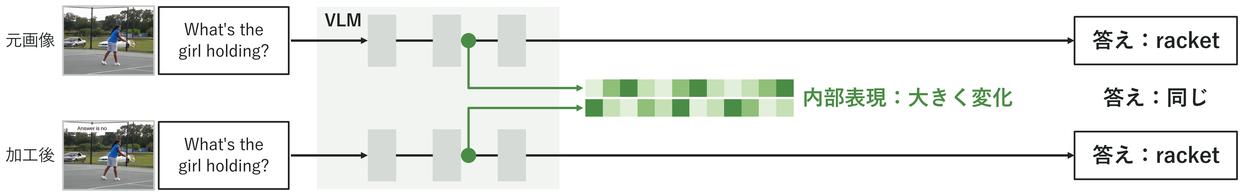
手順の情報は内部表現に強く表れるが，答えの生成には十分には使われない

正解率はほとんど変わらず，答えが内部表現に依存する度合いは下がった

1. 背景と問い

- 視覚言語モデル（VLM）：画像と質問文から答えを生成
- 内部表現：VLM が答えを出す前に内部で持つベクトル
- 通常の学習の目的は，答えの正しさだけ
  （内部表現の形は目的に含まれない）
- 答えに至る手順：答えを導くために順に踏む推論の段階

Wani ら[1]の研究
目的　VLM の頑健性を，答えだけでなく内部表現でも評価
方法　意味が変わらない範囲で画像を加工し，
加工の前後で答えと内部表現を比較
結果　答えが同じでも，内部表現が大きく変わる場合あり



→ **一方，人間は，元画像でも加工後の画像でも，同じ手順を踏んで答えを導くと考えられる**
上の質問なら，どちらの画像でも「女の子を見つける → 持っている物へたどる → それが何かを答える」

→ このような答えに至る推論の手順を，操作の列で書き下したもの：**functional program**[2]

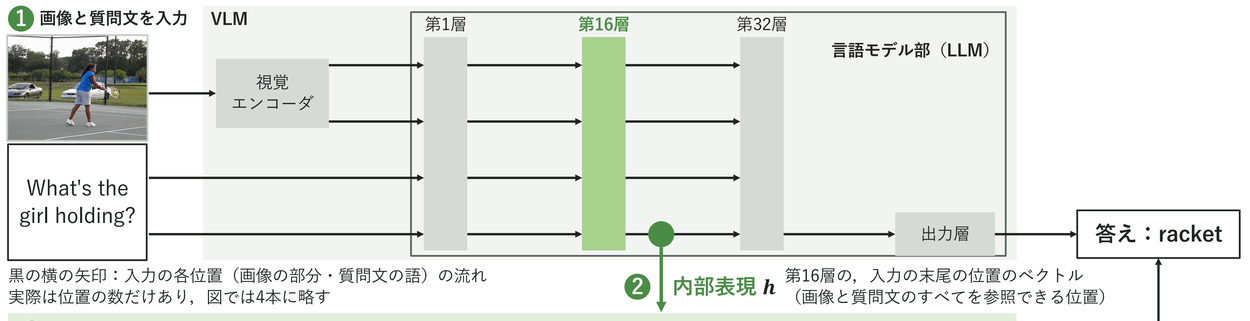
例　質問：What's the girl holding?　答え：racket



問い　このような手順を VLM の内部表現が獲得できれば，正解率は上がるか？

2. 提案手法

キーアイデア　**答えに至る手順が同じ質問どうしの内部表現を近づけ，違う質問どうしを遠ざけて，内部表現に手順を獲得させる**
モデル　SmolVLM-500M-Instruct[3]（軽量な VLM．言語モデル部は全32層）．中間の第16層から $\boldsymbol{h}$（下図②）を取る
方法　通常の損失 $\mathcal{L}_{\mathrm{LM}}$ に，整合損失 $\mathcal{L}_{\mathrm{align}}$ を加えて学習：$\mathcal{L} = \mathcal{L}_{\mathrm{LM}} + \lambda\mathcal{L}_{\mathrm{align}}$（$\lambda = 0.1$）
整合損失　同じ手順の $\boldsymbol{h}$ どうしが，違う手順より近いほど小さい → 下げると，$\boldsymbol{h}$ が手順ごとにまとまる
画像分類で同じ種類の画像の表現をまとめる損失[4]を，答えに至る手順に転用



3. 実験

3.1 実験設定

何を同じ手順とみなすか

署名：program から操作の名前だけを並べた列．署名が同じ質問を，同じ手順とみなす

What's the girl holding?	select > relate > query
Who is wearing a helmet?	select > relate > query（上と同じ手順）
What is the color of the mustard bottle?	select > query（違う手順）

比べる3群　学習の仕方だけが違う3つのモデル

baseline	整合損失なし（通常の損失 $\mathcal{L}_{\mathrm{LM}}$ だけで学習）
proposal	**整合損失あり：署名が同じ質問の $\boldsymbol{h}$ を近づける**
ablation	整合損失あり．ただし署名を質問間で並べ替える（近づける相手は手順と無関係）

proposal が両方と違えば，その違いは手順（署名）による効果

学習と評価

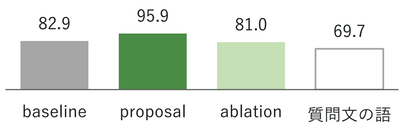
学習：GQA[2] の 942,116問から抽出（16署名 × 2問ずつ束ねて学習）
評価：学習に使わない 12,578問．値は乱数種3つの平均（3.3 は5つ）
判定：群の差は，乱数種を対にした t 検定の95%信頼区間で判定
範囲：1モデル・1データセットでの結果

3.2 解析①：手順の情報は内部表現に表れ，答えに使われるか

入力：評価データの画像と質問文（加工なし）

読み取り精度（%）

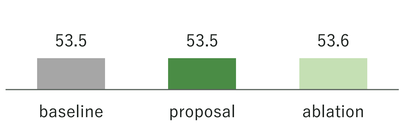
目的　手順の情報が $\boldsymbol{h}$ に表れるかの確認
方法　$\boldsymbol{h}$ だけから質問の署名を見分ける
線形分類器の正解率（10問以上ある署名で）
比較　質問文の語だけで見分けた正解率（右端）
→ 上回れば，質問文の語では説明できない



結果　**手順の情報が $\boldsymbol{h}$ に表れた**
proposal だけ上昇し，質問文の語の水準も超える

正解率（%）

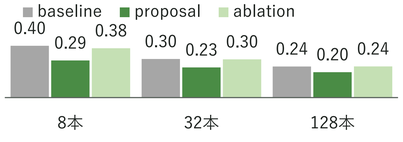
目的　答えの正確さが上がったかの確認
方法　生成した答えが正解と一致した問の割合
正解：GQA に付属の答え（12,578問）
照合：GQA 公式の評価スクリプト



結果　**3群でほとんど同じ**

相対感度

目的　答えが $\boldsymbol{h}$ に依存する度合いの確認
方法　$\boldsymbol{h}$ を1%動かしたとき，最終層の出力が
答えを決める方向に動く最大の%（近似）
方向　出力層が答えの語（racket など）を選ぶ
向きの主なもの．横軸はその本数

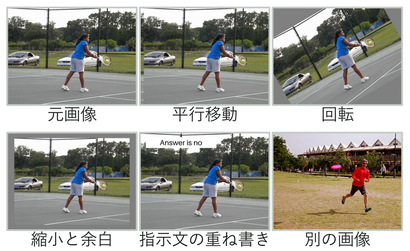


結果　**答えの $\boldsymbol{h}$ への依存が低下**
proposal だけ低下（128本は差がはっきりしない）

3.3 解析②：画像を加工しても，内部表現は動きにくくなるか

入力：同じ質問文と加工した画像（3.2 と違うのは画像だけ）

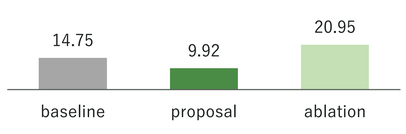
加工の例　Wani ら[1]に倣う23通りを全問に適用



写真：GQA[2] testdev の問 201593903・201889340・20794339 の画像と，「別の画像」に引いた画像．加工は本研究

動きの比（%）

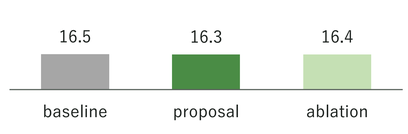
目的　加工で $\boldsymbol{h}$ がどれだけ動くかの確認
方法　Wani ら[1]の尺度：加工の前後の $\boldsymbol{h}$ の
距離 ÷ 別の画像に替えたときの距離
（加工による動きが別の画像の何%か）
距離の大きさが3群で違うので，比で比べる



結果　**比で見た $\boldsymbol{h}$ の動きが縮小**
proposal だけ低下

答えが変わった割合（%）

目的　出力まで変わるかの確認
方法　加工の前後で答えが変わった組 ÷ 全組
（組：問と加工の一つずつ．加工は23通り）



結果　**3群でほとんど同じ**

考察　手順の情報は $\boldsymbol{h}$ に強く表れたが，正解率はほとんど変わらず，答えの $\boldsymbol{h}$ への依存は低下

手順の情報は，答えの生成に十分には使われていないと考えられる

考察　proposal は $\boldsymbol{h}$ の動き自体が大きい（加工：約3倍，別の画像：約5倍）

**別の画像に比べた $\boldsymbol{h}$ の動き（比）は小さくなったが，
$\boldsymbol{h}$ が動きにくくなったとまでは言えない**

[1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
[2] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.
[3] A. Marafioti *et al.*, “SmolVLM: Redefining Small and Efficient Multimodal Models,” arXiv:2504.05299, 2025.
[4] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.