P3-15

タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

中野 友晴，杉村 大輔（東京都立大学）

アイデア

質問に答える手順を，VLM の内部表現に明示的に持たせる

「見つける → たどる → 答える」のような手順が同じ質問どうしを，内部表現でも近づける

わかったこと

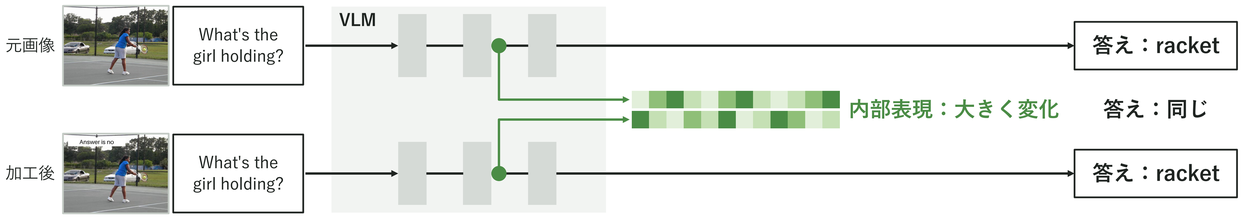
手順の情報は内部表現に強く表れるが，答えの生成には十分使われない

正解率の上昇は見られず，答えが内部表現に頼る度合いは下がった

1. 背景と問い

- VLM（視覚言語モデル）：画像と質問文から答えを生成
- 内部表現：VLM が答えを出す前に内部で持つベクトル
- 通常の学習の目的は，答えの正しさだけ
  （内部表現の形は目的に含まれない）

Wani ら[1]の研究
目的　VLM の頑健性を，答えだけでなく内部表現でも評価
方法　意味が変わらない範囲で画像を加工し，
　　加工の前後で答えと内部表現を比較
結果　答えが同じでも，内部表現が大きく変わる場合あり



→ 人間が画像を見て答えに至るまでの手順の特徴を，内部表現は獲得できていない可能性

答えに至る手順の例：What's the girl holding? → racket

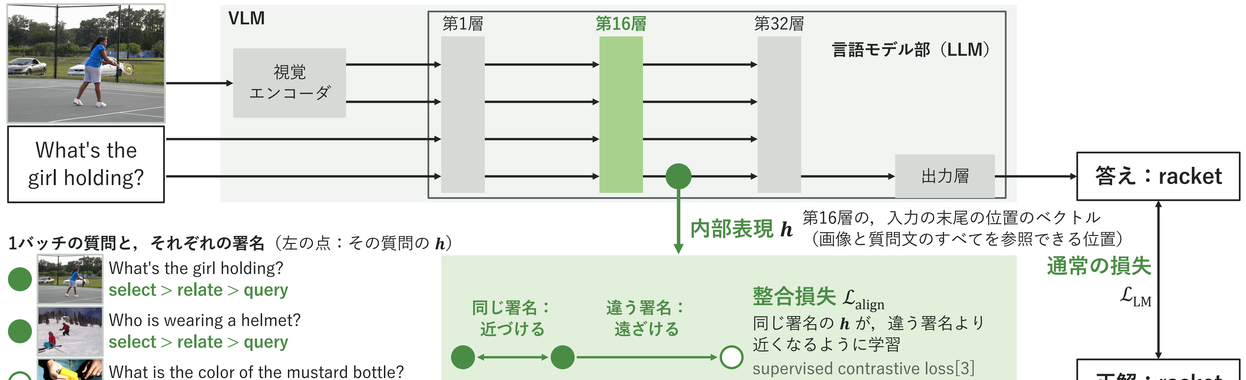


問い　**手順の情報を内部表現に強く持たせれば，VLM はそれを答えの生成に使い，正解率は上がるか？**

2. 提案手法

キーアイデア　**手順が同じ質問どうしの内部表現を近づけ，違う質問どうしを遠ざける**
理由　物体が違っても手順が同じ質問は多数
　→ 内部表現が手順ごとにまとまれば，手順の情報を共通に利用でき，答えの正確さの向上を期待
手順の判定　タスク署名（以下，署名）が一致すれば，同じ手順とみなす
　タスク署名：データセット GQA[2] が各質問に付ける
　手順の記述から，操作の名前だけを並べた列（右の例）
学習　通常の損失 $\mathcal{L}_{\mathrm{LM}}$ に，整合損失 $\mathcal{L}_{\mathrm{align}}$ を追加：$\mathcal{L} = \mathcal{L}_{\mathrm{LM}} + \lambda \mathcal{L}_{\mathrm{align}}$（$\lambda = 0.1$）

例　What's the girl holding?
select: girl
relate: holding → **select > relate > query**
query: name　操作の名前だけを並べた列



3. 実験

3.1 実験設定

モデル：SmolVLM-500M-Instruct[4]　**評価**：12,578問（学習に不使用）
学習：GQA[2] 942,116問から抽出（1バッチは16署名 × 2問）

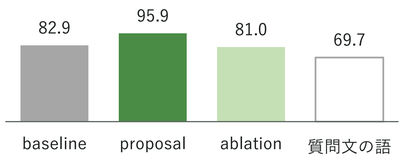
群	整合のラベル
baseline	整合なし
proposal	**質問の署名**
ablation	質問と対応しない署名（並べ替え）

- baseline とも ablation とも違えば，署名の効果
- 3群 × 3乱数種 = 9回学習．値は平均（3.3 は5乱数種）
- 群の差の区間：乱数種を対にした t 検定（対応のある t 検定）の95%信頼区間

3.2 手順の情報は内部表現に表れ，答えに使われるか

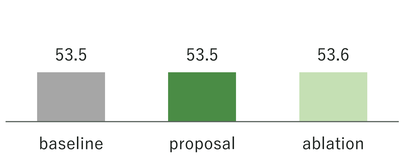
入力：評価データの画像と質問文（加工なし）

読み取り精度（%）
目的　手順の情報が $\boldsymbol{h}$ に表れるかの確認
方法　$\boldsymbol{h}$ から署名を当てる線形分類器の正解率
　（10問以上ある署名の問．半数で学習）
対照　入力を質問文の語にした同じ分類器
　（質問文だけで当たる水準）



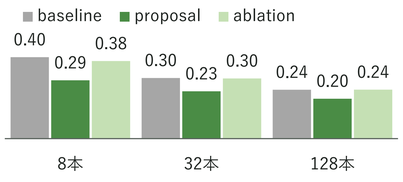
結果　**proposal だけ上昇**
baseline との差：　+13.0pt [+11.6, +14.4]
質問文の語の分類器も上回る

正解率（%）
目的　答えの正確さが上がったかの確認
方法　GQA 公式の評価スクリプト（12,578問）



結果　**群の差の向きは決められず**
baseline との差：　−0.06pt [−1.81, +1.70]

相対感度
目的　答えが $\boldsymbol{h}$ に頼る度合いの確認．
　読める情報が使われるとは限らない[5]
方法　出力層で答えの語に当たる重みの主成分を
　答えを決める方向とする（横軸の本数）
　$\boldsymbol{h}$ を1%動かしたとき最終層がその方向に
　動く最大の%（近似）を，方向と64問で平均

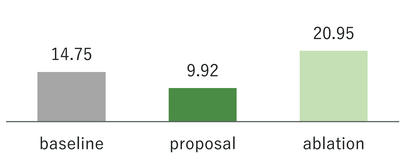


結果　**8・32本で proposal だけ低下**
baseline との差：　8本　−28.0% [−44.4, −11.5]
　32本　−21.6% [−38.1, −5.2]
　128本　−18.0% [−36.4, +0.3]

3.3 内部表現は，画像の加工に対して安定になるか

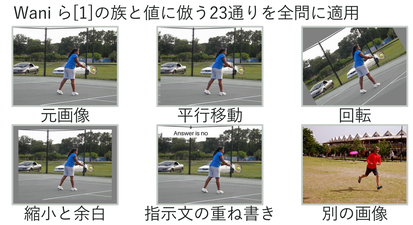
入力：同じ質問文と加工した画像（3.2 と違うのは画像だけ．予稿以後の測定）

比（%）
目的　加工で $\boldsymbol{h}$ がどれだけ動くかの確認
　群ごとに距離の尺度が違うので，比で比較
方法　加工の前後の $\boldsymbol{h}$ のコサイン距離の平均 ÷
　同じ質問・別の画像での距離の平均
　（比の形は Wani ら[1]に倣う）



結果　**proposal が最小**
baseline との差：　−4.82pt [−7.87, −1.77]

加工の例
Wani ら[1]の族と値に倣う23通りを全問に適用



答えが変わる割合
目的　出力まで変わるかの確認
方法　加工の前後で答えが変わった問の割合

結果　**群の差の向きは決められず**
baseline との差：　−0.14pt [−0.60, +0.32]

考察　手順の情報は $\boldsymbol{h}$ に強く表れたが，正解率の上昇は見られず，答えが $\boldsymbol{h}$ に頼る度合いは低下

手順の情報は，答えの生成に十分使われていないと考えられる

考察　proposal は $\boldsymbol{h}$ の動き自体が大きい（加工：約3倍，別の画像：約5倍）

**別の画像に比べて，加工による $\boldsymbol{h}$ の動きは小さくなったが，
安定性が高まったとまでは言えない**

4. まとめ

研究の概要
手順が同じ質問の内部表現を
近づける学習を VLM に追加し，
内部表現と答えの生成への影響を検証

結果
- **読み取り精度**：proposal だけ上昇
- **正解率**：群の差の向きは決められず
- **相対感度**：8・32本で proposal だけ低下
- **比**：proposal が最小

考察
- 内部表現の形は変わったが，
  答えの生成に使われるように
  なったとは言えない
- 別の画像に比べて，加工による
  $\boldsymbol{h}$ の動きは小さくなったが，
  安定性が高まったとまでは言えない

1モデル・1データセットでの結果
（整合は第16層，$\lambda = 0.1$）

[1] F. A. Wani *et al.*, “Same Answer, Different Representations: Hidden Instability in VLMs,” arXiv:2602.06652, 2026.
[2] D. A. Hudson and C. D. Manning, “GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering,” in Proc. *IEEE/CVF CVPR*, 2019.
[3] P. Khosla *et al.*, “Supervised Contrastive Learning,” in Proc. *NeurIPS*, 2020.
[4] A. Marafioti *et al.*, “SmolVLM: Redefining Small and Efficient Multimodal Models,” arXiv:2504.05299, 2025.
[5] Y. Elazar *et al.*, “Amnesic Probing: Behavioral Explanation with Amnesic Counterfactuals,” *TACL*, 2021.
画像：GQA[2] testdev の問 201593903・201889340・20794339 の画像と，対照に引いた画像．加工は本研究．