P3-15

タスク類似性に基づく内部表現整合学習が視覚言語モデルの出力に与える影響

中野 友晴，杉村 大輔（東京都立大学）

問い

答えに至る手順を視覚言語モデルの内部表現が獲得できれば，正解率は上がるか？

例　質問：What's the girl holding?
　　手順：女の子を見つける → 持っている物へたどる → それが何かを答える

わかったこと

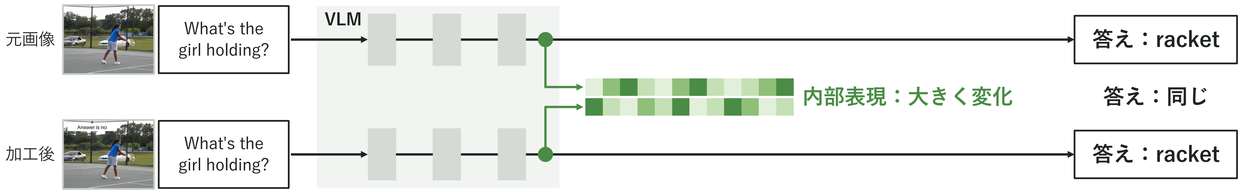
手順の情報は内部表現に強く表れるが，答えの生成に十分には使われていない

手順の情報を持たせても，正解率はほとんど変わらず，答えが内部表現に依存する度合いは下がった

1. 背景と問い

- 視覚言語モデル（VLM）：画像と質問文から答えを生成
- 内部表現：VLM が答えを出すまでの途中で計算するベクトル
- 通常の学習が求めるのは，答えの正しさだけで，内部表現の形は問わない
- 答えに至る手順：答えを導くために順に踏む推論の段階

Wani ら[1]の研究
目的　VLM の頑健性を，答えだけでなく内部表現でも評価
方法　意味が変わらない範囲で画像を加工し，加工の前後で答えと内部表現を比較
結果　答えが同じでも，内部表現が大きく変わる場合あり



→ **一方，人間は，元画像でも加工後の画像でも，同じ手順を踏んで答えを導くと考えられる**
　上の質問なら，どちらの画像でも「女の子を見つける → 持っている物へたどる → それが何かを答える」

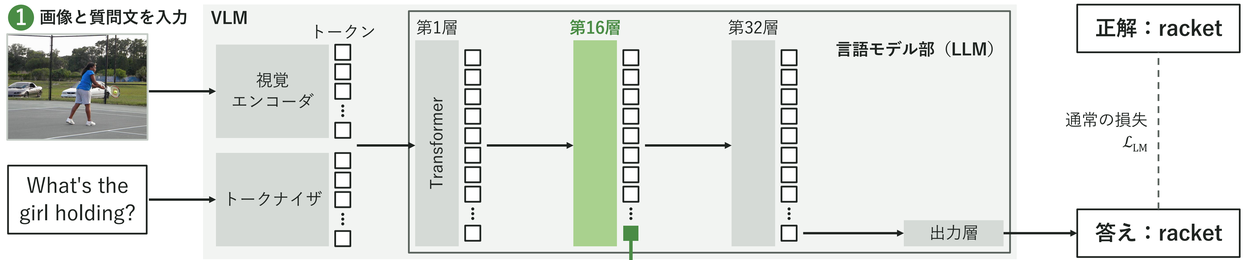
→ このような答えに至る推論の手順を，操作の列で書き下したもの：**functional program**[2]
例　質問：What's the girl holding?　答え：racket



問い　このような手順を VLM の内部表現が獲得できれば，正解率は上がるか？

2. 提案手法

キーアイデア　**答えに至る手順が同じ質問どうしの内部表現を近づけ，違えば遠ざけて，内部表現に手順の情報を持たせる**
モデル　SmolVLM-500M-Instruct[3]：言語モデル部が全32層の軽量な VLM．中間の第16層から，下図❷の $\boldsymbol{h}$ を取る
方法　通常の損失 $\mathcal{L}_{\mathrm{LM}}$ に，整合損失 $\mathcal{L}_{\mathrm{align}}$ を加えて学習：$\mathcal{L} = \mathcal{L}_{\mathrm{LM}} + \lambda\mathcal{L}_{\mathrm{align}}$，重み $\lambda = 0.1$
整合損失　$\boldsymbol{h}$ を手順ごとにまとめる損失
　画像分類で同じ種類の画像の表現をまとめる損失[4]を転用

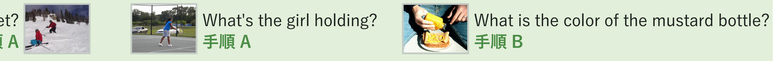


トークン：画像の部分や質問文の語などを表すベクトル
層への矢印：全トークンが次の層へ進む．出力層へは末尾のトークンだけ

❷ **内部表現 $\boldsymbol{h}$**　第16層で，入力の末尾の位置にあるベクトル
　この位置は，画像と質問文のすべてを参照できる

❸ **整合損失 $\mathcal{L}_{\mathrm{align}}$**

正方形：各質問の $\boldsymbol{h}$．同じ色は同じ手順



3. 実験

3.1 実験設定

何を同じ手順とみなすか

What's the girl holding?	select > relate > query	
Who is wearing a helmet?	select > relate > query	上と同じ手順
What is the color of the mustard bottle?	select > query	違う手順

署名：functional program から操作の名前だけを並べた列．署名が同じ質問を，同じ手順とみなす

比べる3群　学習の仕方だけが違う3つのモデル

- baseline　整合損失なし：通常の損失 $\mathcal{L}_{\mathrm{LM}}$ だけで学習
- **proposal**　**整合損失あり：署名が同じ質問の $\boldsymbol{h}$ を近づける**
- ablation　整合損失あり：署名を質問どうしで無作為に入れ替え，手順と無関係な相手を近づける

proposal が両方と違えば，その違いは署名の意味による効果

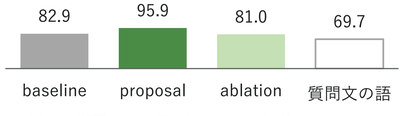
学習と評価

学習：GQA[2] の942,116問から16署名 × 2問を引いて更新し，これを29,441回
評価：学習に使わない12,578問，3.2 の相対感度は64問．値は乱数種3つの平均，3.3 では5つ
判定：乱数種を対にした t 検定で求めた，群の差の95%信頼区間が 0 を含まなければ差あり
範囲：1モデル・1データセットでの結果

3.2 解析①：手順の情報は内部表現に表れ，答えに使われるか

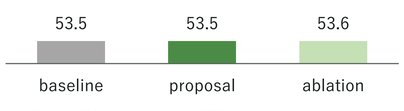
入力：評価データの質問文と，加工していない画像

読み取り精度（%）
目的　手順の情報が $\boldsymbol{h}$ に表れるかの確認
方法　$\boldsymbol{h}$ だけから線形分類で質問の署名を見分ける
　10問以上ある署名で，正しく見分けた割合
比較　右端は，質問文の語だけで見分けた割合
　→ $\boldsymbol{h}$ が上回れば，語だけでは説明できない



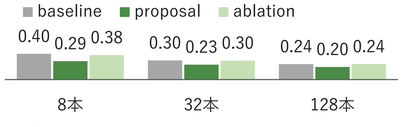
結果　**手順の情報が $\boldsymbol{h}$ に表れた**
proposal だけ上昇．3群とも質問文の語を超える

正解率（%）
目的　答えの正確さが上がったかの確認
方法　生成した答えが正解と一致した問の割合
　照合：GQA 公式の評価スクリプト



結果　**3群でほとんど同じ**

相対感度
目的　答えが $\boldsymbol{h}$ に依存する度合いの確認
方法　$\boldsymbol{h}$ を1%動かしたとき，第32層の出力が答えを決める方向に動く%の平均
方向　racket などの答えの語を選ぶ，出力層の主な向き．横軸は取った向きの本数



結果　**答えの $\boldsymbol{h}$ への依存が低下**
proposal だけ低下．128本は差がはっきりしない

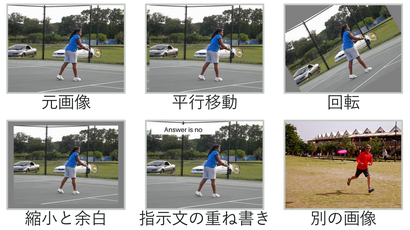
考察　手順の情報は $\boldsymbol{h}$ に強く表れたが，正解率はほとんど変わらず，答えの $\boldsymbol{h}$ への依存は低下

手順の情報は，答えの生成に
十分には使われていないと考えられる

3.3 解析②：画像を加工しても，内部表現は動きにくくなるか

入力：同じ質問文と加工した画像．3.2 と違うのは画像だけ

加工の例　Wani ら[1]に倣う23通りを全問に適用



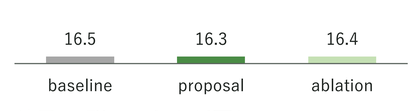
1–3章の写真の出典：GQA[2] の評価データ
問 201593903・201889340・20794339 の画像
3.3 の加工は本研究による．「別の画像」は説明のための例

動きの比（%）
目的　加工で $\boldsymbol{h}$ がどれだけ動くかの確認
方法　Wani ら[1]に倣う尺度：加工の前後の $\boldsymbol{h}$ の距離 ÷ 画像だけ替えたときの距離
　加工の動きが，画像だけ替えたときの何%か
　分母の距離が3群で違うので，比を使う



結果　**比で見た $\boldsymbol{h}$ の動きが縮小**
proposal だけ低下

答えが変わった割合（%）
目的　答えまで変わるかの確認
方法　加工の前後で答えが変わった組 ÷ 全組
　組：問1つと加工1つ．加工は23通り



結果　**3群でほとんど同じ**

考察　proposal は $\boldsymbol{h}$ の動き自体が baseline より大きい．加工で約3倍，別の画像で約5倍

$\boldsymbol{h}$ の動きの比は小さくなったが，
$\boldsymbol{h}$ が動きにくくなったとまでは言えない

[1] F. A. Wani *et al.*, "Same Answer, Different Representations: Hidden Instability in VLMs," arXiv:2602.06652, 2026.
[2] D. A. Hudson and C. D. Manning, "GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering," in Proc. *IEEE/CVF CVPR*, 2019.
[3] A. Marafioti *et al.*, "SmolVLM: Redefining Small and Efficient Multimodal Models," arXiv:2504.05299, 2025.
[4] P. Khosla *et al.*, "Supervised Contrastive Learning," in Proc. *NeurIPS*, 2020.